

Otimização do monitoramento das condições de equipamentos de mineração utilizando IoT com aprendizado de máquina

Cid Clay Aparecido Quirino^{1*}; Eder Costa Cassettari²

¹ Cid Clay Quirino. Mestre em Engenharia Mecânica. Avenida Assis de Vasconcelos 542 – Campina; 66017-070 Belém, Pará, Brasil, Telefone: 31 99899-6108, Endereço eletrônico: cidclay@gmail.com

² Doutorado em Engenharia Mecânica. Endereço profissional, Universidade de São Paulo, USP, Brasil, Campus Piracicaba - Luiz de Queiroz, rua Alexandre Herculano 120, Monteiro – Piracicaba, 13418900, SP – Brasil, Telefone: 19 33770937, Endereço eletrônico: E-mail para contato: eder.cassettari@usp.br

Otimização do monitoramento das condições de equipamentos de mineração utilizando IoT com aprendizado de máquina

Resumo

A crescente demanda por maior confiabilidade e redução de falhas em ativos críticos de mineração, como escavadeiras hidráulicas, em que componentes menores muitas vezes não são monitorados adequadamente, é uma oportunidade de avançar na otimização de processos de manutenção preditiva em equipamentos de mineração utilizando tecnologias de IoT e aprendizado de máquina. O objetivo deste estudo foi testar o uso de sensoriamento de pequenos componentes para o monitoramento contínuo de variáveis como temperatura e vibração, em contrapartida aos fluxos manuais ainda utilizados com frequência nas operações. A metodologia incluiu a coleta de dados em campo por sensores IoT instalados nos componentes e o uso de técnicas de aprendizado de máquina para a análise preditiva das falhas. A base de dados foi tratada e analisada utilizando algoritmos como Gated Recurrent Unit [GRU], Long Short-Term Memory [LSTM] e Support Vector Regression [SVR], com a projeção de temperatura. Entre os principais resultados, observou-se que os modelos de aprendizado profundo, especialmente GRU e LSTM, apresentaram alto desempenho preditivo, reduzindo significativamente o risco de falhas não planejadas. O estudo concluiu que a integração de IoT com técnicas avançadas de modelagem pode otimizar a manutenção preditiva em ambientes de mineração, proporcionando ganhos operacionais e maior segurança.

Palavras-chave: manutenção preditiva; otimização de processos; manutenção preventiva.

Introdução

Estudos recentes mostram avanços no monitoramento de equipamentos industriais, tendo como objetivos a eliminação da presença física de seres humanos devido aos riscos inerentes e a dificuldade de acesso aos locais de execução, além da redução na parada dos equipamentos com a antecipação de falhas. Este avanço iniciou-se na década de 1990, como indica Tian et al. (1992), escrevendo sobre o aumento da produtividade e utilização dos equipamentos industriais. Assim, a eficiência e a produção com o aumento no nível de automação estão cada vez mais relacionados, apontando ainda mais para a necessidade de melhorar o monitoramento da saúde dos ativos.

Para Park et al (2016), a manutenção preditiva atrai mais interesse do que a manutenção de rotina (manutenção realizada quando ocorre uma falha na máquina). Eles atribuem isso ao fato das técnicas de manutenção preditiva ajudarem a determinar a condição dos equipamentos ou sistemas em serviço, e possibilitarem avaliar e prever quando a manutenção deverá ser realizada. Desta forma, a manutenção preditiva permite o agendamento conveniente de ações corretivas planejadas e evita paradas inesperadas do equipamento, visto que, a chave é a informação certa no momento certo. Ao saber previamente quais equipamentos ou componentes precisarão de manutenção, os responsáveis por este departamento, poderão antecipar as ações. Assim o que seriam

paradas de manutenção corretiva, são transformadas em paradas planejadas, ou seja, intervenções mais curtas e mais eficientes, aumentando assim a disponibilidade dos ativos.

A manutenção preditiva geralmente utiliza técnicas estatísticas de controle de processos para determinar em que ponto as futuras atividades de manutenção serão apropriadas. Além disso, Gbadamosi et al (2021) observam que algumas abordagens atuais exigem o envio de inspetores para o local, a fim de verificar os ativos em operação, o que representa mais riscos para a saúde e a segurança dos trabalhadores. Por outro lado, quando existe um monitoramento eficiente das máquinas com métodos inovadores, como por exemplo coleta “online”, esse risco pode ser reduzido ou até mesmo eliminado.

No contexto da mineração, alguns componentes como motores e pneus já possuem um monitoramento aprimorado. No entanto, componentes menores, como bombas e cilindros hidráulicos, são frequentemente monitorados de forma indireta, o que pode dificultar a tomada de decisões em caso de princípio de falha. Seruffo et al. (2022) relatam sobre a necessidade crescente por processos digitalizados a partir da evolução tecnológica ocorrida com a chegada da Indústria 4.0. Também abordam o acesso a dados de maneira mais rápida, intuitiva e barata e ainda sugerem pontos de desenvolvimento de soluções viáveis e de baixo custo.

A possibilidade de avançar sobre o processo de Gerenciamento de Monitoramento de Condições [GMC], ampliando a cobertura para os pequenos componentes, utilizando, para tal, a aplicação de sensores de temperatura e vibração, coletando dados em tempo real ao longo de uma série temporal, é uma oportunidade ainda não explorada. Este trabalho foca no desenvolvimento e aplicação de alternativas viáveis para coleta de dados e análise de projeção de saúde em pequenos componentes. Com isso, espera-se produzir avanços na manutenção preditiva e na redução de falhas prematuras, reduzindo o tempo de inatividade e atendendo aos requisitos de segurança com a menor exposição aos riscos humanos durante a inspeção. Diante disso, foi elaborado um projeto de sensoriamento com Internet das Coisas [IoT] para pequenos componentes em uma escavadeira hidráulica de mineração em uma operação de mina a céu aberto.

Materiais e Métodos

As etapas deste trabalho são descritas a seguir na Figura 1 desde a análise inicial até a conclusão, com base em uma Estrutura Analítica do Projeto [EAP] simples e didática.

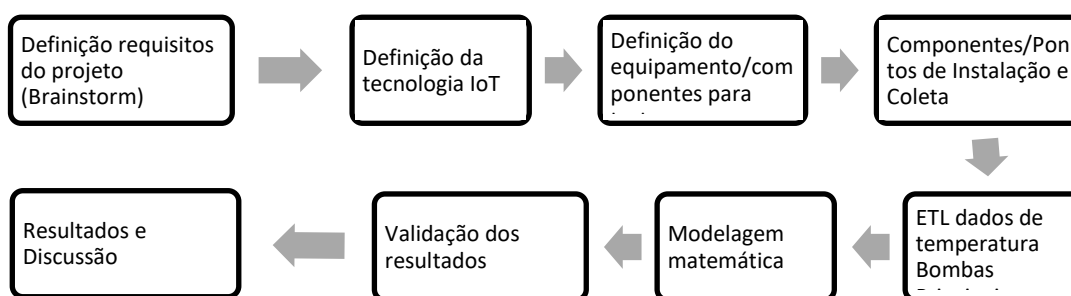


Figura 1. Estrutura Analítica do Projeto [EAP] do projeto produto/processo

Fonte: Dados originais da pesquisa

Para este estudo, foi utilizada uma base de dados com 8.226 observações de temperatura e vibração de duas bombas principais da escavadeira Caterpillar® modelo 395 durante o período de 17 dias de operação (11 set 2024 até 28 set 2024, compondo 8.226 observações). Para estratificação e análise dos dados foi utilizado o Software Python com interface do Google Colab. Os dados foram extraídos em um formato .csv e tratados utilizando as bibliotecas descritas abaixo:

- **numpy:** Usada principalmente para manipulação e operações de arrays numéricos de forma eficiente. Neste trabalho, ela foi utilizada para realizar cálculos matemáticos, criar sequências de números, manipular vetores de tempo e processar dados, bem como para manipulação de dados de séries temporais, cálculos de matrizes e vetores de valores de temperatura.
- **pandas:** Essencial para a manipulação e análise de dados em “DataFrames”. Ela é amplamente usada para séries temporais e processamento de grandes conjuntos de dados. Foi utilizada para lidar com índices temporais, para manipulação dos dados de temperatura, para realizar operações como filtragem, agregação e cálculos de médias móveis.
- **matplotlib.pyplot:** Utilizada para gerar gráficos e visualizações simples. Ela permite plotar séries temporais de temperatura e outras variáveis associadas, e foi utilizado para gerar gráficos de linha para exibir a evolução da temperatura ao longo do tempo.
- **seaborn:** É uma biblioteca de visualização que se baseia no matplotlib e oferece gráficos mais sofisticados e estilos aprimorados. Foi utilizada neste estudo para gerar gráficos estatísticos, como mapas de calor ou visualizações de correlações entre variáveis de temperatura.
- **sklearn:** É utilizada para modelar a relação entre as variáveis de entrada e a variável de saída. Foi aplicado neste estudo para modelar e prever a temperatura baseada em séries temporais passadas.

- tensorflow: É uma biblioteca de aprendizado profundo e machine learning e foi utilizado para implementar redes neurais recorrentes (LSTM/GRU) para prever temperaturas futuras com base em dados de séries temporais.

Manutenção: Corretiva, Preventiva e Preditiva

Nascimento et al. (2020) descreve os três tipos de manutenção de equipamentos. A manutenção corretiva pode ser descrita como a modalidade de manutenção aplicada após a ocorrência da falha, com a finalidade de colocar o ativo em funcionamento após a perda da funcionalidade, e pode ser dividida em dois tipos, corretiva planejada e não planejada. A manutenção preventiva é a modalidade de manutenção aplicada com o intuito de diminuir a probabilidade de falha e manter o desempenho. É desenvolvida com base em procedimentos, planos de manutenção e inspeções, e executada em intervalos regulares, onde ocorre a substituição ou o reparo de itens anormais. Por fim, a manutenção preditiva se utiliza de dados para as análises em pontos específicos do ativo, tais como conferência de nível de óleo, análises de vibração e temperatura. É comumente aplicada com a finalidade de monitorar o padrão de funcionamento do ativo e identificar potenciais falhas.

Esta última modalidade de manutenção se caracteriza pelo uso de instrumentos de medição e coleta massiva de dados como ferramenta de apoio, para a tomada de decisão. Neste sentido, o uso de IoT vem sendo amplamente adotado pela indústria, para o avanço das técnicas de manutenção preditiva. O uso de IoTs e seu avanço na indústria 4.0, será a base do presente estudo que visa otimizar a condição de equipamentos de mineração. O uso da manutenção preditiva e IoT constitui a base para aumentar a coleta e disponibilidade de dados de máquinas, e avançar na atuação preditiva.

Oliveira (2023) descrevem que as máquinas e equipamentos industriais não foram construídos para durar para sempre, mas, por outro lado, podem durar muito mais. Ele acrescenta que os eventos de falhas de ativos são processos de degradação, que podem ser didaticamente apresentados por meio da curva de falha potencial *versus* falha funcional (P-F), vista na Figura 2.




Figura 2. Representação da condição de um equipamento ou componente ao longo do tempo, indicando a curva de falha potencial *versus* falha funcional (P-F)

Fonte: Oliveira (2023)

Oliveira (2023), em seu estudo, aponta a importância da utilização de tecnologias no monitoramento do intervalo P-F como uma estratégia inteligente, com maior assertividade e confiabilidade na manutenção dos seus equipamentos. Dessa forma a equipe de manutenção pode evitar as quebras repentinas, e a correção das falhas identificadas entre os pontos P e F da curva, minimizando a ocorrência de falha funcional.

Internet das Coisas

Segundo Dias et al. (2022), o termo Internet das Coisas foi criado por Kevin Ashton por volta de 1999 em uma apresentação sobre o gerenciamento da cadeia de suprimentos. Posteriormente o termo foi apresentado pelo comitê técnico conjunto da International Organization for Standardization [ISO] e da Comissão Eletrotécnica Internacional [IEC], que definiram Internet das Coisas como sendo uma infraestrutura composta por objetos, pessoas, sistemas e recursos de informação todos interconectados. Acrescenta-se a isso os serviços inteligentes para permitir que eles processem informações sobre o mundo físico e virtual.

Na Figura 3 é apresentado o aumento do número de dispositivos de IoT por ano, onde Dias et al. (2022) avaliam tanto o aumento considerável de projetos de pesquisa quanto a quantidade de dispositivos, demonstrando o interesse tanto da academia quanto das empresas/pessoas por esta solução.




Figura 3: Número de dispositivos IoT por ano em bilhões de unidades

Fonte: J.P. Dias et al. (2022)

Como citado por Aguirre-Jofré (2021), a IoT pode ser considerada um mundo onde os objetos físicos estão perfeitamente conectados à rede de informações, se tornando parte ativa dos fluxos e processos de negócios. O autor comenta que o surgimento da IoT de baixo custo promete acesso generalizado a sensores e dados que podem ser usados para a tomada de decisões operacionais. Em seu estudo sobre o uso da IoT, foi analisado um caso real onde foi aplicado um sistema para informar mudanças na gestão operacional que resultaram na redução do tempo de carregamento. Na Figura 4, é apresentado um esquema que é aplicado em situações como a otimização das rotas dos caminhões de mineração e controle da velocidade dos caminhões para maior segurança, sem aumento no custo de mineração.





Figura 4. Sequência esquemática de um sistema de gestão operacional via Internet das Coisas, partindo do dispositivo até a aplicação em si

Fonte: H. Aguirre-Jofré et al. (2021)

O estudo aqui apresentado faz uso de dispositivos de IoTs de custo significativamente baixos, com uma camada de análise estática e algoritmos que buscam otimizar o processo de análise dos dados. Esta segunda camada de análise faz uso de técnicas de “Machine Learning” para identificar variações nos padrões de comportamento nos parâmetros. Neste estudo, a instalação dos sensores foi feita considerando os pequenos componentes que não são cobertos pelo monitoramento do fabricante (Figura 5).






Figura 5. Instalação dos dispositivos IoT (temperatura/vibração) nos componentes em campo de uma escavadeira hidráulica de mineração em uma operação de mina a céu aberto

Fonte: Dados originais da pesquisa

Estes sensores coletam, e enviam para um repositório na nuvem, os dados de temperatura e vibração em um intervalo pré-definido de 10 minutos. O detalhamento deste fluxo, bem como a configuração estão descritos nos tópicos posteriores, tal como os detalhes sobre a aplicação, coleta e tratamento dos dados.

Importante informar, que este trabalho teve inspiração na análise de temperatura com câmera térmica, realizada desde 2018, a qual obteve resultados promissores em termos de monitoramento preditivo, como explicado em detalhes a seguir neste estudo.

Com base nesse trabalho anterior, foi sugerido a otimização do método, empregando mecanismos de Internet das Coisas (IoT) para obter dados diretamente dos componentes, possibilitando a análise de dados para detectar alterações de temperatura e vibração mais rapidamente e com maior precisão.

Definição da tecnologia IoT

Uma proposta de solução foi requerida e esquematizada na Figura 6 com sendo um aprimoramento no processo de monitoramento, a fim de estruturar uma análise robusta, com uso de tecnologia de sensoriamento online, métodos estatísticos e suporte decisório mais sólido.



Figura 6. Dados coletados pela solução Dynamox para cada componente de uma escavadeira Caterpillar® 395

Fonte: Dados originais da pesquisa

O equipamento/modelo definido para o piloto deste estudo em campo foi a escavadeira hidráulica Caterpillar® modelo 395 utilizando a câmera termográfica, pelo fato de que este modelo de ativo foi o mesmo utilizado no primeiro trabalho, pela quantidade de ativos deste modelo em campo e pela sua criticidade para a produção nos clientes.

Os componentes bomba principal P1 e bomba principal P2 foram escolhidos tanto por serem os mais críticos para o funcionamento do ativo quanto pelo custo, impacto na disponibilidade física e por causarem um dado consequentes alto quando em uma parada não programada.

Armazenamento na Nuvem

Considerando os desafios de implementação e a necessidade de ter um maior foco na camada de análise estatística (Data Science), optou-se pelo uso de um sensor que coleta temperatura e vibração e que já possui todo o ecossistema de IoT desenvolvido. Isso eliminou a necessidade de estabelecer todo este processo, permitindo o avanço diretamente para a parte de análise estatística dos dados.

Como apontado também por Dias et al. (2022), existem pontos críticos nesta etapa do processo, são elas: a heterogeneidade, distribuição lógica e geográfica, preocupações humanas, necessidades de comunicação em tempo real e restrições de energia. Estes pontos desempenham um papel fundamental no projeto, desenvolvimento, testes e manutenção da IoT mais adequada. Com base nessa complexidade, neste estudo foi utilizada a solução integrada da empresa Dynamox, e foram adquiridos para isso os sensores para instalação em

campo, além de um dispositivo Gateway. Em paralelo, a empresa também disponibilizou o Sistema DynaPredict, que disponibilizou os dados na nuvem. Por meio de uma interface de Programação de Aplicações [API], a empresa disponibilizou a base da empresa no Google Cloud para receber os dados de campo de cada um dos sensores de forma online, via o Gateway, utilizando sistema GSN 2, 3 ou 4g (Figura 7).



Figura 7. Visão da árvore de componentes da nuvem de dados no Google Cloud

Fonte: Dados originais da pesquisa

Por fim, com esta arquitetura relativamente simples, foi possível avançar para a etapa de análise dos dados e na identificação de possíveis padrões, que pudessem ser identificados como potenciais falhas em componentes.

Trabalhos relacionados/Estudo de caso

Este estudo foi aplicado sem quaisquer usos de tecnologia embarcada, mas com a utilização de um inspetor e uma câmera tecnográfica. O procedimento operacional requerido demandou uma série de atividades obrigatórias para melhor compreensão de algum desvio nos parâmetros. Após seguidas todas as etapas de avaliação de desempenho conforme descrito pelo fabricante, foi possível a obtenção dos dados de temperatura, tempo de descida e subida do cilindro, pressão hidráulica durante os testes, taxa de fluxo das bombas hidráulicas.

A pressão hidráulica do equipamento antes de realizar o teste de velocidade de descida e subida do implemento foi de 5171,8 Pa. Somente após estes pontos estarem dentro do parâmetro especificação, o teste de temperatura por termografia foi conduzido, em paralelo

aos testes de tempo de ciclo e pressão, resultando em 58 °C. Utilizando uma câmera termográfica foram feitas medições nas temperaturas, procurando identificar possível diferencial térmico entre os cilindros. Conforme ilustrado na Figura 6, observado um diferencial de temperatura de 4,7°C em relação ao lado esquerdo. Os pontos mais quentes dos cilindros foram capturados pela câmera, revelando uma diferença de temperatura de ~5°C entre o cilindro de elevação do lado direito [l/d] e o cilindro de elevação do lado esquerdo [l/e] (Figura 8).




Figura 8. A) Termografia nos Cilindros de Elevação da Escavadeira; B) Termográfica com 5°C entre os pontos dos cilindros de elevação da lança de uma escavadeira Caterpillar® 395
Fonte: Dados originais da pesquisa

Após remover e desmontar o cilindro na oficina de reparos, foi possível confirmar que os sintomas observados no campo foram importantes para definir e concluir que o método termográfico pode ser usado com mais segurança para determinar a necessidade de remoção (Figura 9). Isso resultou em uma redução, embora não significativa, nos custos de reparo e no impacto na contaminação do sistema hidráulico. As Figuras 9B, 9C e 9D fornecem detalhes adicionais após a desmontagem e análise do cilindro, sendo que o modo de falha apresentado na Figura 8B ilustra a causa do aumento de temperatura no processo termográfico de campo.




Figura 9. A) Cilindro na Centro de Reforma; B, C e C) Falha interna cilindro após desmontagem e peritagem

Fonte: Dados originais da pesquisa

Com isso, foi possível entender que mesmo tendo sido avaliado antecipadamente, a frequência em que foram realizadas as inspeções e coletas em campo permitiram um avanço da falha até um nível que o sistema já havia sido contaminado. Apesar de ter sido removido antes de uma falha catastrófica, tal abordagem permitiu avanço significativo na parte interna do componente.

Após os resultados utilizando fluxo anterior, e consequentemente com base na conclusão após desmontagem e reforma, as principais questões a serem investigadas são: Qual a forma de avançar no processo de coleta e análise dos dados de temperatura a tempo de remover o componente, sem que ele possa estar em um estado de degradação avançado? Como mitigar isso? Como antecipar a falha, a ponto de não deixar esse Modo de Falha ocorrer?

ETL dados de temperatura Bombas Principais P1 e P2

Foram instalados sensores nos componentes, bem como a integração com a base de dados da Dynamox. Posteriormente, foi feita a integração dos dados disponibilizados na Cloud. Foram removidos os dados de vibração para ambas as bombas, para que o foco deste estudo de análise fosse somente a temperatura de ambas as bombas.

Modelagem matemática

Nielsen (2020) ressalta o aumento exponencial do uso das séries temporais, inicialmente com a medicina tendo o pioneirismo na geração de dados, vindo posteriormente a meteorologia e o mercado de “trading” e astronomia.

Anderson et al. (2023) define uma série temporal como sendo um conjunto de variáveis ordenadas em função do tempo, e avalia que o estudo e modelagem destes dados é fundamental para compreender o comportamento e realizar previsões sobre determinados dados. Ele orienta para a necessidade de realização de um estudo do tipo de série temporal que está sendo objeto de análise e projeção, e que, em caso de observar que os dados possuem tendência estocástica, é preciso avaliar, pois isso pode tornar as previsões imprecisas, conforme se afastam do último ponto da amostra. Para isso, ele orienta a utilização do procedimento para a avaliação da estacionariedade da série, por meio do teste Augmented Dickey-Fuller [ADF], como sendo um dos testes de raiz unitária mais tradicionais. A seguir, as Equações 1, 2 e 3 representando o teste de Dickey-Fuller.

$$y_t = \phi y_{t-1} + u_t \quad (1)$$

$$y_t = \beta_1 + \phi y_{t-1} + u_t \quad (2)$$

$$y_t = \beta_1 + \beta_2 t + \phi y_{t-1} + u_t \quad (3)$$

em que ϕ é um parâmetro a ser estimado, u_t é um processo de ruído branco, que se caracteriza como uma sequência de variáveis aleatórias independentes e identicamente distribuídas (iid), com média zero e variância constante ($u_t \sim RB(0, \sigma^2)$), β_1 é uma constante que representa o intercepto e β_2 é um efeito de tendência. O teste considera como hipótese nula, $H_0 : \phi = 1$, a presença de raiz unitária e como hipótese alternativa, $H_1 : \phi < 1$, a série sendo estacionária.

De acordo com Silveira et al. (2022), na presença de estacionariedade, a função amostral que descreve o processo gerador dos dados tem a mesma forma em todos os instantes, facilitando a identificação de estimativas dos parâmetros desconhecidos dos modelos especificados. O autor relaciona alguns avanços nos testes de *Augmented Dickey-Fuller* (ADF), sugere a utilização do cálculo do valor-p (p-value) como determinado a partir da estatística t no teste ADF, e menciona possíveis interferências no resultado.

Nielsen (2020) explica que se a série temporal é estacionária, simplifica significativamente a análise e modelagem, pois indica que suas propriedades estatísticas,

como média, variância e autocorrelação, permanecem constantes ao longo do tempo. Isso permite aplicar uma variedade de técnicas de modelagem e previsão com mais confiança.

Nielsen (2020) separa os modelos estatísticos de séries temporais entre estáticos, modelos de espaço de estado e aprendizado de máquina. Neste estudo, avaliação e definição do modelo mais aderente estará condicionada aos resultados de Erro Médio Absoluto [MAE], Erro Quadrático Médio [MSE], Raiz do Erro Quadrático Médio [RMSE], Critério de Informação de Akaike [AIC] e Coeficiente de Determinação [R^2] para definição dos modelos com melhor performance, conforme descrito por Géron (2021) como exemplos de alguns dos métodos estatísticos desenvolvidos para séries temporais.

Como concluído por Nielsen (2020), modelos complicados nem sempre são os melhores, pois o custo-benefício compensa o uso de recursos computacionais adicionais requeridos para sua operação. Em uma análise e definição de um modelo, é importante pensar se o tempo de treinamento adicional para operar com um modelo de aprendizagem de máquinas complexo vale a pena.

Nielsen (2020) também apresenta as diferenças entre os modelos de séries temporais univariadas, que possuem apenas uma variável medida ao longo do tempo, e séries temporais multivariadas, que são séries com múltiplas variáveis medidas a cada “timestamp”. Estas últimas são muito úteis para análise, pois muitas vezes as variáveis calculadas são inter-relacionadas e mostram dependências temporais entre si.

Neste estudo, a série temporal base possui dados de temperatura e vibração de pequenos componentes da escavadeira Caterpillar® 395. Contudo, a análise se concentrará em somente uma variável ao longo do tempo. Durante a avaliação dos dados, foi identificado que, ao se observar uma variação pequena na temperatura dos componentes, se obtinha um impacto significativo nos resultados das métricas avaliadas. Com base nesse comportamento, foi utilizada a transformação de Box-Cox para estabilização da variância e para tornar os dados mais simétricos, o que é particularmente útil quando a série temporal original exibe variância não constante (heterocedasticidade), assim como visto em Young (2023).

Adicionalmente, foi utilizada a técnica de combinação de Box-Cox e GARCH nos dados de temperatura das Bombas P1 e P2, com o objetivo de aprimorar a precisão dos modelos ao lidar com dados de séries temporais voláteis e com distribuições não normais, pois também segundo Young (2023), os métodos de GARCH e transformação Box-Cox auxiliam na redução de problemas relacionados à heterocedasticidade e não-normalidade nos resíduos, isso se os resíduos apresentarem correlação serial, heterocedasticidade e não-normalidade.

Finalmente, Fávero (2024), comenta sobre a análise de modelos de regressão linear com o objetivo avaliar qual o parâmetro para definição deste, se seria o R^2 ou outro

parâmetro, e descreve que a definição da melhor forma funcional é uma questão empírica, em favor do melhor ajuste ao modelo em estudo. Neste estudo em específico, a determinação do modelo com melhor ajuste foi feita utilizando o cálculo do Log-Likelihood, pois como abordado por Yanze (2023), este conceito desempenha um papel fundamental no processo de modelagem probabilística. O Log-Likelihood é utilizado como uma função de objetivo para otimizar a previsão da distribuição conjunta dos dados observados. Yanze (2023) propõe a fatoração do Log-Likelihood para permitir uma maior flexibilidade no tratamento de séries temporais com irregularidades. Isso é feito ao condicionar a função de verossimilhança nas informações condicionais, a fim de facilitar a captura das variações temporais e a dependência do caminho. Além disso, o Log-Likelihood é utilizado como métrica principal para avaliar a qualidade do modelo proposto em comparação com outros modelos existentes. O processo de fatoração da verossimilhança permite que o modelo capture as variações de tempo e heterogeneidades estatísticas nos dados, tornando-o mais adaptável a séries temporais complexas, como aquelas com amostras irregulares.

O teste ADF (Augmented Dickey-Fuller) examinou a hipótese nula de que uma série temporal é não-estacionária, complementados pelo teste KPSS (Kwiatkowski-Phillips-Schmidt-Shin), que considera a hipótese nula de estacionariedade.

Foram feitos com o objetivo de avaliar os resultados de métricas de performance/aderência dos modelos à série temporal estudada. A definição para o modelo mais aderente para trabalhar com séries temporais, depende de vários fatores, incluindo a estrutura dos dados, a quantidade de dados disponíveis, a presença de tendências ou sazonalidades, entre outros. Algumas técnicas de AST&P (Advanced Statistical Techniques & Procedures) foram utilizadas neste estudo, como a consideração dos resultados dos modelos quanto a sua aderência aos dados de ambos os componentes, a Bomba P1 e Bomba P2, e às métricas MAE, MSE, RMSE, AIC, e R^2 .

Todos os códigos, dados e registros de imagens estão disponíveis no link <https://github.com/CidClayQuirino/rnn-component-llfe-cycle>.

Resultados e Discussão

Os dados de temperatura apresentaram o comportamento ilustrado pela Figura 10.




Figura 10. Distribuição das temperaturas de A) Bomba P1 e B) Bomba P2 de uma escavadeira Caterpillar® 395

Fonte: Resultados originais da pesquisa

A distribuição dos dados de temperatura das bombas P1 e P2 é apresentada na Figura 11.

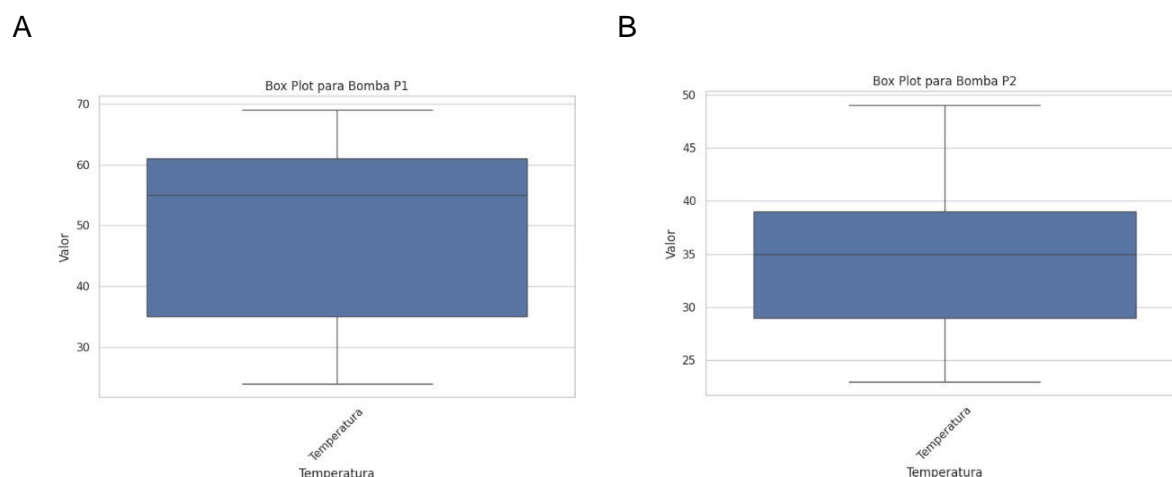
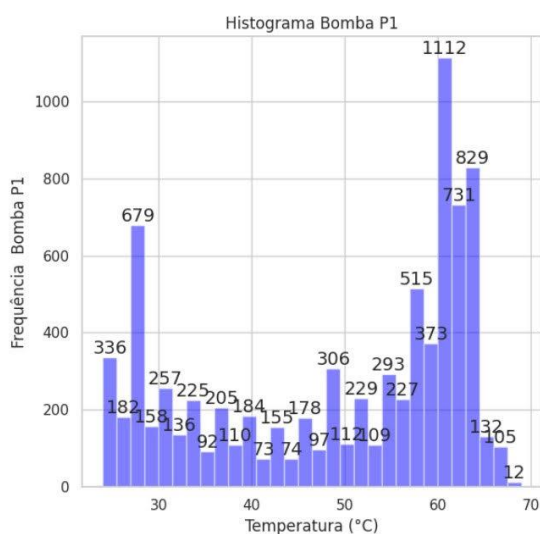


Figura 11. Resumo dados temperatura de A) Bomba P1 e B) Bomba P2 de uma escavadeira Caterpillar® 395

Fonte: Resultados originais da pesquisa

Na amostra coletada para este estudo, observou-se uma concentração de valores de temperatura formando uma assíntota à esquerda para os dados da Bomba P1, e uma assíntota à direita para os dados da Bomba P2 (Figura 12).

A



B

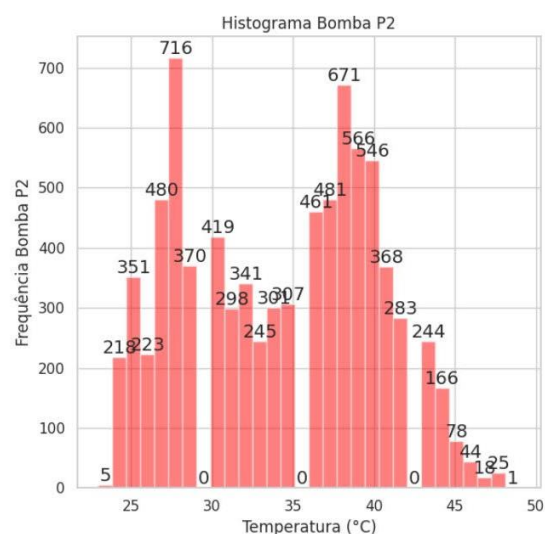




Figura 12. Histograma dos dados de temperatura de A) Bomba P1 e B) Bomba P2 uma escavadeira Caterpillar® 395

Fonte: Resultados originais da pesquisa

Conforme mostrado nas Figura 13A e 13B, todas as séries temporais são estacionárias, sem raiz unitária, em um nível de significância convencional ($p < 0,05$).

A



B

Figura 13. Teste de Augmented Dickey-Fuller [ADF] para estacionariedade da série temporal de dados de temperatura de A) Bomba P1 e B) Bomba P2 de uma escavadeira Caterpillar® 395

Fonte: Resultados originais da pesquisa

Os modelos que apresentaram maior aderência estão indicados em negrito na Tabela

1.

Tabela 1. Ranking para seleção de modelos preditivos treinados com dados de temperatura de Bomba P1 e Bomba P2 de uma escavadeira Caterpillar® 395. MAE: Erro Médio Absoluto; MSE: Erro Quadrático Médio; R²: Coeficiente de Determinação; AIC: Critério de Informação de Akaike; RMSE: Raiz do Erro Quadrático Médio. Linhas em negrito representam os três modelos com maior aderência aos dados dentre todos testados

Modelo	Ranking					
	MAE	MSE	R ²	AIC	RMSE	Total
RNNLSTMBombaP1	1,0	1,0	2,0	2,0	1,0	7,0
RNNGRUBombaP1	2,0	2,0	1,0	4,0	2,0	11,0
SVR_AjusBombaP1	3,0	3,0	3,0	1,0	3,0	13,0
SVRBombaP1	4,0	4,0	4,0	5,0	4,0	21,0
RLMBombaP1	5,0	5,0	5,0	3,0	5,0	23,0
SARIMAXBombaP1	6,0	6,0	6,0	6,0	6,0	30,0
ARIMABombaP1	7,0	7,0	7,0	7,0	7,0	35,0
RNNLSTMBombaP2	1,0	1,0	2,0	1,0	1,0	6,0
RNNGRUBombaP2	2,0	2,0	1,0	4,0	2,0	11,0
SVR_AjusBombaP2	3,0	3,0	3,0	2,0	3,0	14,0
SVRBombaP2	4,0	4,0	4,0	5,0	4,0	21,0
RLMBombaP2	6,0	6,0	5,0	3,0	6,0	26,0
ARIMABombaP2	5,0	5,0	7,0	7,0	5,0	29,0
SARIMAXBombaP2	7,0	7,0	6,0	6,0	7,0	33,0

Fonte: Resultados originais da pesquisa

Para a Bomba P1, o modelo LSTM se destaca como o melhor modelo devido ao desempenho superior em todas as métricas, especialmente MAE, MSE, RMSE e AIC. Mesmo caso para a Bomba P2 o LSTM obteve bons resultados. O SVR, mesmo tendo sido utilizadas técnicas de ajuste com melhores parâmetros (RandomizedSearchCV), não obteve resultados satisfatórios, se comparado ao GRU e LSTM.

Para a Bomba P2, LSTM é claramente o melhor modelo, com os melhores resultados em todas as métricas. O GRU também apresentou resultados satisfatórios, com MAE, MSE e R², bem como também se destacaram os resultados de RMSE, AIC. Para os dados desse componente, o SVR obteve resultados inferiores ao LSTM e GRU.

Em suma, os modelos de GRU e LSTM obtiveram resultados bem mais aderentes aos dados, com os menores MAE e MSE e os R² mais altos. Alinhado a isso, também o modelo SVR_Ajustado com Randomized Search CV, como técnica de otimização de hiper parâmetros, maximizou a performance e apresentou melhoria no desempenho a ponto de ajustar mais a estes dados do que o modelo básico sem ajustes.

Em relação ao modelo GARCH, no caso da Bomba P1, a série de dados apresentou média estável de 37,55, mas também alta volatilidade, sendo que o modelo GARCH mostra que a volatilidade da série é amplamente impactada por choques recentes ($\alpha_1 = 0,9348$), enquanto a persistência de longo prazo da volatilidade ($\beta_1 = 0,0505$) foi menor (Figura 14).

A

Sumário do GARCH para MainPumpP1:				
Constant Mean - GARCH Model Results				
=====				
Dep. Variable:	Value	R-squared:	0.000	
Mean Model:	Constant Mean	Adj. R-squared:	0.000	
Vol Model:	GARCH	Log-Likelihood:	-27441.7	
Distribution:	Normal	AIC:	54891.3	
Method:	Maximum Likelihood	BIC:	54919.4	
		No. Observations:	8226	
Date:	Sun, Oct 20 2024	Df Residuals:	8225	
Time:	17:15:35	Df Model:	1	
Mean Model				
=====				
	coef	std err	t	P> t 95.0% Conf. Int.
mu	60.7432	0.107	570.273	0.000 [60.534, 60.952]
Volatility Model				
	coef	std err	t	P> t 95.0% Conf. Int.
omega	1.4366	0.107	13.367	9.472e-41 [1.226, 1.647]
alpha[1]	0.9678	2.043e-02	47.360	0.000 [0.928, 1.008]
beta[1]	0.0000	2.764e-02	0.000	1.000 [-5.417e-02, 5.417e-02]

B

Sumário do GARCH para MainPumpP2:				
Constant Mean - GARCH Model Results				
Dep. Variable:	Value	R-squared:	0.00	
Mean Model:	Constant Mean	Adj. R-squared:	0.00	
Vol Model:	GARCH	Log-Likelihood:	-23453.3	
Distribution:	Normal	AIC:	46914.7	
Method:	Maximum Likelihood	BIC:	46942.7	
Date:	Sun, Oct 20 2024	No. Observations:	8226	
Time:	17:15:37	Df Residuals:	8225	
		Df Model:	1	
Mean Model				
	coef	std err	t	P> t 95.0% Conf. Int.
mu	37.5513	0.125	301.594	0.000 [37.307, 37.795]
Volatility Model				
	coef	std err	t	P> t 95.0% Conf. Int.
omega	0.8274	7.011e-02	11.802	3.830e-32 [0.690, 0.965]
alpha[1]	0.9348	1.388e-02	67.367	0.000 [0.908, 0.962]
beta[1]	0.0505	1.676e-02	3.013	2.587e-03 [1.765e-02, 8.336e-02]

Figura 14. Sumário do modelo GARCH para dados de temperatura de A) Bomba P1 e B) Bomba P2 de uma escavadeira Caterpillar® 395
Fonte: Resultados originais da pesquisa

Já para a Bomba P2, o modelo GARCH indica uma alta dependência de eventos recentes na volatilidade e uma média relativamente estável, também uma baixa persistência de longo prazo da volatilidade, o que pode ser entendido como sendo pelo fato de que os choques passados possam estar sendo rapidamente absorvidos pela série. A significância dos parâmetros sugere que o modelo está bem ajustado para capturar a dinâmica da volatilidade dessa série temporal.

A Bomba P1 teve ajuste ligeiramente melhor, com base no AIC (54891,3) e log-likelihood (-27441,7) comparativamente a Bomba P2 (AIC = 4691,7; log-likelihood = -23453,3), com parâmetro de persistência de volatilidade (β) insignificante para Bomba P2, sugerindo que este modelo GARCH captura apenas os efeitos de choques recentes, sem persistência de volatilidade.

Ambos os modelos LSTM e GRU apresentam altos valores de α , indicando que os choques recentes têm grande impacto na volatilidade futura. A variância incondicional (ω) é maior para Bomba P2, sugerindo que maior volatilidade não foi explicada no modelo.


Após a aplicação da transformação por Box Cox e aplicada a análise de resíduos para Bomba P1 e Bomba P2 pelo teste Shapiro-Wilk, observou-se p-valores extremamente baixos tanto para LSTM, GRU e SVR, o que indica que não há evidências para a rejeição da hipótese nula de distribuição não aderente à normalidade.

A AIC para a Bomba P1 (46914,7) e para a Bomba P2 (54891,3) auxiliou na comparação entre a qualidade dos modelos, considerando que neste caso quanto menor, melhor. O modelo de Bomba P1 tem um AIC menor, sugerindo que ele pode ser um ajuste ligeiramente melhor para os dados do que o modelo para Bomba P2.

O resultado para o Log-Likelihood da Bomba P1 (-23453,3) e Bomba P2 (-27441,7) foi mais uma métrica usada na avaliação de modelos, onde valores mais altos, isto é, menos negativos, indicam melhor ajuste. Neste caso, a Bomba P1 tem um log-likelihood maior, sugerindo um melhor ajuste comparado a Bomba P2.


A avaliação detalhada dos resultados permite identificar potenciais áreas de melhoria com uso de dados mássicos, coleta instantânea e análise estatística a fim de garantir o funcionamento eficiente e seguro das bombas Bomba P1 e Bomba P2 para os próximos períodos. Adicionalmente, a projeção com o modelo LSTM/GRU e SVR com transformação Box-Cox e GARCH é apresentada na Figura 15 utilizando os dados de temperatura para a Bomba P1 e para Bomba P2.

Previsões de Modelos vs Valores Reais para MainPumpP1 com Transformação BoxCox




A

Previsões de Modelos vs Valores Reais para MainPumpP1 com GARCH Model Results




B

Previsões de Modelos vs Valores Reais para MainPumpP2 com Transformação BoxCox



C



D

Figura 15. Projeção de previsão de temperatura com o modelo LSTM/GRU e SVR com transformação de Box-Cox para A) Bomba P1 e C) Bomba P2 e modelo LSTM/GRU e SVR com método GARCH para B) Bomba P1 e D) Bomba P2 de uma escavadeira Caterpillar® 395
Fonte: Resultados originais da pesquisa

Observou-se em todos os casos uma forte aderência aos modelos com dados de teste e treino, tendo sido utilizado a Transformação de Box-Cox e GARCH com o objetivo de ajustar os dados. Em todos os casos, os modelos baseados em redes neurais (LSTM e GRU) superaram os modelos tradicionais (SARIMAX, ARIMA e SVM), com o LSTM mostrando desempenho superior, especialmente para a Bomba P2, apresentando as melhores métricas e maior aderência aos dados.

As funções ACF (Autocorrelação) e PACF (Autocorrelação Parcial) dos resíduos dos modelos LSTM e GRU indicam que praticamente todos os lags estão dentro dos limites de confiança, sugerindo ausência de autocorrelação significativa (Figura 16). Isso demonstra que os modelos capturam bem os padrões temporais, sem deixar dependências seriais nos resíduos. Já o modelo SVR apresenta um comportamento diferente, com ACF mostrando alta autocorrelação nos primeiros lags, que diminui lentamente, e PACF confirmando essa correlação nos primeiros lags, especialmente no lag 1.

Nesta etapa da avaliação, os modelos LSTM e GRU mostraram-se mais adequados em ajustar-se aos dados, uma vez que seus resíduos não apresentaram autocorrelações significativas, sugerindo que os padrões temporais foram bem capturados. Em contraste, o modelo SVR apresentou autocorrelações persistentes nos resíduos, o que aponta para a necessidade de ajustes ou a consideração de outro modelo mais apropriado para captar as dinâmicas temporais.

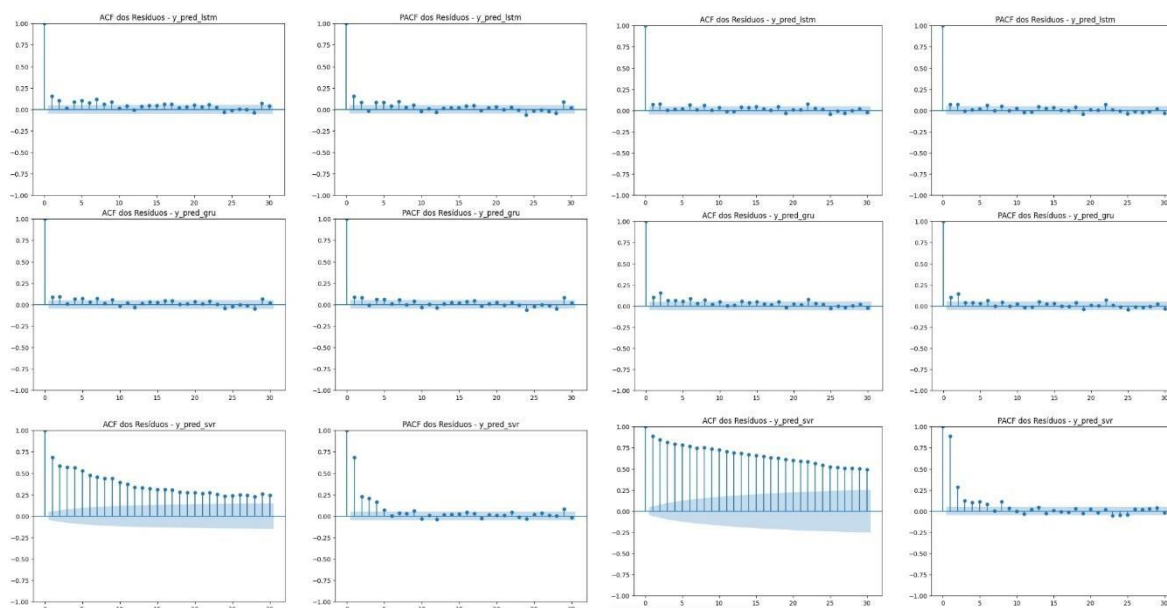


Figura 16. ACF (Autocorrelação) e PACF (Autocorrelação Parcial) dos resíduos dos modelos LSTM (acima), GRU (meio) e SVR (abaixo) para a predição de temperatura de Bomba P1 (esquerda) e Bomba P2 (direita) de uma escavadeira Caterpillar® 395

Fonte: Resultados originais da pesquisa

Ao avançar na análise dos resultados dos modelos LSTM, GRU e SVR_Ajustado, buscou-se entender melhor o comportamento dos resíduos, tanto para a Bomba P1 quanto para a Bomba P2, neste caso adicionando um quadro comparativo para os testes de Shapiro-Wilk, Kolmogorov-Smirnov, Durbin-Watson e Breusch-Pagan (Tabela 2).

Tabela 2: Resultados do teste estatísticos dos modelos GRU, LSTM, SVM e SVR Ajustado para predição de temperatura de Bomba P1 e Bomba P2 de uma escavadeira Caterpillar® 395

Teste	Análise
Shapiro-Wilk (Teste de Normalidade)	<p>Para a Bomba P1, todos os modelos (GRU, LSTM, SVM, SVR_Ajus) têm p-valores extremamente baixos (na ordem de $10e-32$ $10e-32$), o que significa que os resíduos não seguem uma distribuição normal.</p> <p>Para a Bomba P2, ocorre o mesmo, com p-valores próximos a $10e-32$, indicando não-normalidade dos resíduos.</p>
Kolmogorov-Smirnov (Ajuste da Distribuição)	<p>Para a Bomba P1, todos os modelos mostram p-valores muito baixos, especialmente o SVM e SVR_Ajus (com um estatístico de 0,537).</p> <p>Para a Bomba P2, o modelo GRU também mostra p-valores baixos, indicando má adequação dos resíduos.</p>

Durbin-Watson (Autocorrelação)	<p>Para a Bomba P1: Os modelos GRU (2,94) e LSTM (2,74) estão próximos de 2, indicando baixa autocorrelação. Os modelos SVM e SVR_Ajus apresentam valores muito baixos (~0,26), sugerindo forte autocorrelação positiva.</p> <p>Para a Bomba P2, o modelo GRU mostra um valor baixo (0,62), o que indica autocorrelação significativa.</p>
Breusch-Pagan (Heterocedasticidade)	<p>Para a Bomba P1, o modelo GRU tem um estatístico elevado (143,19) e um p-valor baixo, indicando heterocedasticidade. Os modelos SVM e SVR_Ajus mostram estatísticas extremamente altas e p-valores próximos de zero, indicando forte heterocedasticidade.</p> <p>Para a Bomba P2, o modelo GRU também apresenta alta heterocedasticidade com um valor estatístico de 320,09.</p>

Fonte: Resultados originais da pesquisa

Esses testes são fundamentais para verificar a normalidade dos resíduos, a presença de autocorrelação e heterocedasticidade, garantindo que os modelos estejam adequadamente ajustados e sejam robustos.

Com base na análise dos resíduos, os modelos LSTM e GRU foram os melhores para a Bomba P1, com resultados mais favoráveis nos testes de Durbin-Watson (menor autocorrelação) e Breusch-Pagan (menor heterocedasticidade). No entanto, ambos enfrentam desafios relacionados à normalidade dos resíduos. Para a Bomba P2, o GRU apresentou algum nível de heterocedasticidade e autocorrelação, mas ainda assim teve um desempenho superior ao SVR_Ajustado em termos de ajuste da distribuição.

Em resumo, o modelo LSTM mostrou-se mais consistente, com resíduos próximos de zero e menor dispersão, enquanto o SVR, apesar de uma média de resíduos próxima de zero, exibiu maior variabilidade e resíduos extremos, sugerindo a presença de outliers (Figura 17). O GRU teve desempenho intermediário entre o LSTM e o SVR. Assim, mesmo após a análise dos resíduos, o LSTM demonstrou ser o modelo mais confiável para ambas as bombas, apresentando menos problemas de autocorrelação e heterocedasticidade.

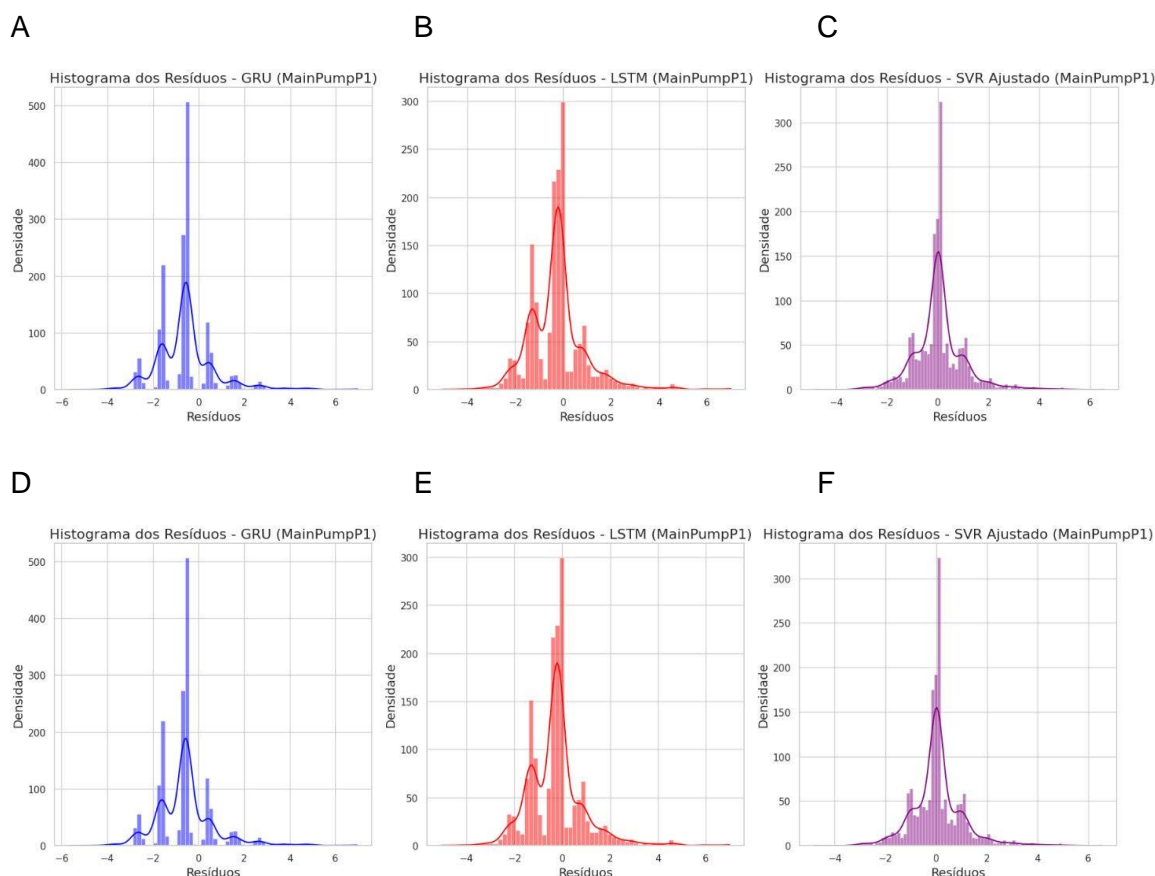


Figura 17. Histograma dos resíduos para os modelos GRU, LSTM e SVR para Bomba P1 (A, B e C) e para Bomba P2 (D, E e F) de uma escavadeira Caterpillar® 395
Fonte: Resultados originais da pesquisa

Avaliação de Overfitting (MSE e MAE para treino e teste)

Para a Bomba P1, o LSTM apresenta uma boa generalização, com os valores de MSE e MAE menores no conjunto de teste em comparação com o de treino, indicando que o modelo não está sofrendo de overfitting e tem boa capacidade de prever os dados de teste. O GRU também apresenta uma boa generalização, com valores de erro no conjunto de teste ligeiramente melhores do que no treino, como o MSE e MAE no teste são menores, o GRU parece ser ligeiramente superior ao LSTM para a Bomba P1. O SVR apresenta erros maiores tanto no treino quanto no teste em comparação com o LSTM e o GRU. Além disso, o erro no conjunto de teste é maior do que no conjunto de treino, sugerindo um possível overfitting ou um modelo mal ajustado.


Para os dados da Bomba P2, novamente, o LSTM apresenta um bom desempenho com valores de erro menores no conjunto de teste, sugerindo uma boa generalização sem overfitting. O GRU tem o melhor desempenho em ambos os conjuntos de treino e teste, com os menores valores de MSE e MAE. Isso indica que o modelo está bem ajustado e é capaz

de generalizar melhor do que o LSTM e SVR para os dados da Bomba P2. O SVR continua apresentando os piores resultados, com valores mais altos de MSE e MAE tanto no conjunto de treino quanto no conjunto de teste. Além disso, o erro no conjunto de teste é ligeiramente superior ao erro no de treino, sugerindo um ajuste fraco e um possível overfitting.


Projeção e Log-Likelihood para modelos SVR, GRU e LSTM

Os resultados obtidos para a amostra de dados coletados demonstraram diferentes comportamentos entre os modelos estudados. Os modelos de aprendizado de máquina, especificamente GRU e LSTM, destacaram-se por seu excelente desempenho em termos de métricas de erro (MAE e MSE) e explicação da variância (R^2).

Esses modelos conseguiram capturar padrões complexos nos dados temporais, tornando-os mais eficazes, bem como na projeção para um período de 10 dias a frente como mostra a Figura 18, na qual é possível identificar que os valores de temperatura não atingiram pontos considerados alarmantes para acionamento do fluxo de preditiva.



A



B

Figura 18. Projeção de temperatura pelos modelos LSTM, GRU e SVR para A) Bomba P1 e B) Bomba P2 de uma escavadeira Caterpillar® 395

Fonte: Resultados originais da pesquisa

No caso da projeção para a Bomba P2 (Figura 18), é possível ver que os valores de temperatura para a previsão com modelo LSTM decaem com o tempo. Com base nos dados disponíveis, o ajuste do modelo é mais adequado quando há mais dados e isso ocorre diariamente com a coleta e upload para o Data Frame e sua posterior análise. Sendo assim, com a contínua atualização e upload dos novos dados, este trabalho tende a se acomodar com o tempo e a contínua coleta dos dados.

Para a Bomba P1, o modelo LSTM tem o valor de Log-Likelihood mais baixo (por volta de -30), indicando que, entre os três modelos, ele tem a menor adequação aos dados. Já o modelo GRU apresenta uma melhora em relação ao LSTM, com um Log-Likelihood próximo de -20, o que indica uma melhor adequação comparativamente ao LSTM. O modelo SVR se destaca como o modelo com o melhor Log-Likelihood (próximo de -15), sendo o mais adequado para essa série temporal de temperatura para a bomba Bomba P1.

Para a Bomba P2, o modelo LSTM ainda tem um desempenho inferior comparado aos outros modelos, com Log-Likelihood próximo de -12,5, o que reflete uma adequação inferior, o modelo GRU apresenta um Log-Likelihood melhor que o LSTM, mas ainda não supera o SVR, com um valor próximo de -10. O modelo SVR, assim como no caso da Bomba P1, novamente apresenta o maior Log-Likelihood, com um valor aproximado de -8, confirmando que é o modelo com melhor adequação para a Bomba P2 também.

Esses resultados indicam que, para essas séries temporais específicas, o SVR é o modelo mais adequado, enquanto o LSTM precisa de ajustes adicionais para melhorar sua performance.

Conclusões

A análise dos dados de temperatura das bombas P1 e P2, com a aplicação de diversos modelos de previsão de séries temporais, resultou em “insights” valiosos sobre o desempenho dos modelos testados. Os modelos GRU e LSTM demonstraram um desempenho superior, evidenciado pelos menores valores de MAE e MSE e altos valores de R^2 , indicando uma maior capacidade de captura dos padrões complexos nos dados. Esses modelos são recomendados para aplicações que requerem alta precisão na previsão de séries temporais, apesar do maior tempo de processamento envolvido.

A técnica de SVR apresentou resultados ruins, contudo com RandomizedSearchCV, conseguiu capturar melhor os padrões, posicionando-se como uma alternativa dentre os

modelos utilizados no estudo. Contudo, nas projeções, esse modelo mostrou-se adequado para o curto prazo. Por outro lado, métodos tradicionais como ARIMA e Suavização Exponencial não conseguiram captar a estrutura complexa dos dados de temperatura, resultando em maiores erros de previsão e menores valores de R^2 . Isso sugere que esses modelos não são adequados para esse tipo específico de análise temporal.

Em resumo, este estudo demonstrou que o uso de técnicas avançadas de aprendizado de máquina, combinadas com métodos estatísticos rigorosos, pode fornecer previsões precisas e úteis para a manutenção preditiva de equipamentos de mineração. A aplicação desses modelos permite uma melhor compreensão e antecipação das falhas, contribuindo para a eficiência operacional e redução de custos com manutenções emergenciais.

Para futuras pesquisas, recomenda-se a exploração de modelos híbridos que combinam diferentes abordagens para capturar a complexidade dos dados ainda mais eficientemente, bem como a aplicação desses métodos a um conjunto mais amplo de componentes e variáveis operacionais. Outra sugestão para abordagem futura é a análise do custo computacional empregado por cada modelo, e posterior ajuste para melhorar os resultados desse custo, tendo a performance adequada para captura de padrões anormais previstos.

Esses resultados reforçam a viabilidade e importância da integração de tecnologias de IoT e machine learning no monitoramento e manutenção de ativos industriais, promovendo avanços na segurança de quem executa, confiabilidade e performance operacional.

Referências

Aguirre-Jofré, H.; Vogt, D.; Eyre, M.; Valerio, S. 2021. Low-cost internet of things (IoT) for monitoring and optimising mining small-scale trucks and surface mining shovels. *Automation in Construction* 131: 103918.

Nielsen, A. 2020. *Análise prática de séries temporais: predição com estatística e aprendizado de máquina*. 1ed. Alta Books, Rio de Janeiro, RJ, Brasil.

Géron, A. 2021. *Mãos à Obra: Aprendizagem de Máquina com Scikit-Learn, Keras e TensorFlow*. 1ed. Alta Books, Rio de Janeiro, RJ, Brasil.

Fávero, L.P.; Belfiore, P. 2017. *Manual de análise de dados: estatística e modelagem multivariada com Excel®, SPSS® e Stata®*. Elsevier, Rio de Janeiro, RJ, Brasil

Seruffo, M.; Ferreira, B.; Pires, Y. 2022. Planejamento e construção de um protótipo de aplicativo mobile para visualização de dados de sistema de monitoramento de máquinas e equipamentos. *Revista Principia - Divulgação Científica e Tecnológica do IFPB* 59(3): 947-966.

Gbadamosi, A.; Oyedele, L.; Davila Delgado, M.; Kusimo, H.; Akanbi, L.; Olawale, O.; Muhammed -Yakubu, N. 2021. IoT for predictive assets monitoring and maintenance: An implementation strategy for the UK rail industry. *Automation in Construction* 122: 103486.

Dias, J.P.; Restivo, A.; Ferreira, H.S. 2022. Designing and constructing internet-of-Things systems: An overview of the ecosystem. Internet of Things 19: 100529.

Nascimento, E.S.; Maroli, K. R.; Dias, G.C.M.; Bovério, M.A. 2020. Gestão de manutenção industrial: Eletrificação de acionamento de terno de moenda. SITEFA 3: 180–191.

Tian, Y.; Fan, G.; Wu, P. 1992. Intelligent diagnosis of equipment health based on IoT and operation large data analysis. Journal of Physics 042070: 1-8.

Yanze Li, Cheuk Hang Leung, Qi Wu 2023. Probabilistic learning of multivariate time series with temporal irregularity. School of Data Science City University of Hong Kong 4: 102139.