

## ARTIGO ORIGINAL

# Uma abordagem de manutenção preditiva baseada em dados internos em tempo real monitoramento de parâmetros

Chulsoon Park<sup>1</sup> & Dughee Moon<sup>1</sup> & Namchul Do<sup>2</sup> & Sung Moon Bae

2

Recebido: 8 de maio de 2015 /Aceito: 12 de outubro de 2015 /Publicado online: 21 de outubro de 2015  
# Springer-Verlag Londres 2015

**Resumo** Como o monitoramento contínuo de componentes ou condições de equipamentos em tempo real não está disponível para máquinas de moldagem por injeção, propomos uma abordagem de manutenção preditiva que utiliza parâmetros do processo de moldagem por injeção em vez de componentes da máquina para avaliar a condição do equipamento. Em abordagem proposta, as decisões de manutenção são tomadas com base na técnica de controle estatístico de processos com dados em tempo real monitoramento dos parâmetros do processo de moldagem por injeção. Primeiro, componentes de máquinas ou equipamentos de máquinas de moldagem por injeção, que necessitam de manutenção, são identificados e, em seguida, parâmetros do processo de moldagem por injeção, que podem ser afetados por mau funcionamento dos componentes previamente identificados, são identificados. Em segundo lugar, a análise de regressão é realizada para selecionar os parâmetros do processo que afetam significativamente a qualidade do lente e requerem um alto grau de atenção. Ao analisar os padrões de séries de dados monitorados em tempo real de parâmetros de processo, podemos diagnosticar o status dos componentes ou equipamento porque os parâmetros do processo são afetados por

componentes ou equipamentos de máquinas. Terceiro, são desenvolvidos modelos estatísticos preditivos para os parâmetros de processo selecionados aplicar técnicas de análise estatística aos dados monitorados série de parâmetros, a fim de identificar tendências anormais. Quarto, quando tendências ou padrões anormais são encontrados com base em técnicas estatísticas de controle de processo, as informações de manutenção de componentes ou equipamentos relacionados são notificadas aos trabalhadores de manutenção. Finalmente, um sistema protótipo é desenvolvido para mostrar viabilidade em um ambiente LabVIEW® e um experimento é realizado para validar a abordagem proposta.

**Palavras-chave** Manutenção preditiva. Processo estatístico ao controle. Monitoramento em tempo real. Baseado em parâmetros internos diagnóstico

## 1. Fundo

Como os fabricantes querem ser competitivos no mercado dinâmico mercado em mudança, eles estão se esforçando muito para aumentar a eficiência dos sistemas de produção, que é parcialmente alcançado através da diminuição de paradas de operação não planejadas. A competitividade dos sistemas de produção é afetada por seus procedimentos de manutenção, bem como pelo projeto e operação de manutenção [1]. Mais de 30% dos custos de manutenção são causados por cronogramas de manutenção mal colocados, que levam a custos de produção desnecessários [2]. Em particular, na linha de produção de moldagem por injeção de lentes de câmeras de telefones, paradas inesperadas pode causar um desperdício de matéria-prima cara que permanece em zonas de bico ou parafuso. Portanto, os fabricantes estão mais interessados na programação exata da manutenção para manter operação suave e evitar paradas inesperadas.

A manutenção é definida como a restauração de sistemas ou produtos para seu status operacional desejado ou tomando todas as medidas disponíveis para mantê-los no status operacional desejado [1]. Geralmente,

\* Cantada Lua Bae  
bsm@gnu.ac.kr  
Parque Chulsoon  
cspark@changwon.ac.kr  
Dughee Lua  
dhmoon@changwon.ac.kr  
Namchul Do  
dnc@gnu.ac.kr

<sup>1</sup> Escola de Engenharia Industrial e Arquitetura Naval, Changwon Universidade Nacional, 20 Changwondaehak-ro, Changwon 51140, Coreia do Sul

<sup>2</sup> Departamento de Engenharia/Engenharia Industrial e de Sistemas Instituto de Pesquisa, Universidade Nacional de Gyeongsang, 501 Jinjudaero, Jinju 52828, Coreia do Sul

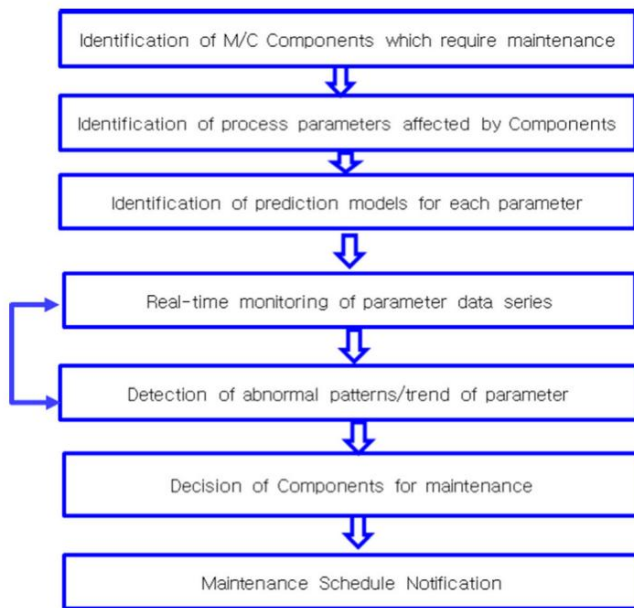


Fig. 1 Procedimento de abordagem de manutenção preditiva

a manutenção pode ser classificada em três categorias: corretiva, manutenção preventiva e preditiva (também conhecida como

manutenção baseada em condições (CBM)) de acordo com os padrões ISO [1, 3, 4]. A manutenção corretiva é definida como restaurar equipamentos ou partes de equipamentos para o status operacional quando os sistemas estão fora de serviço ou as peças estão com defeito. Corretivo a manutenção pode causar alto risco no agendamento da manutenção e desempenho porque não considera o momento de manutenção adequado, ao contrário da manutenção preventiva ou preditiva [5, 6]. A manutenção preventiva é definida como o agendamento de todas as atividades de manutenção para evitar mau funcionamento ou falha e manter o equipamento na condição operacional desejada. Bastante de pesquisa foi gasto na abordagem de manutenção preventiva. Lee e Ni propuseram uma arquitetura de tomada de decisão para determinar políticas de manutenção e envio de produtos com base no monitoramento das condições e na relação dinâmica entre a degradação da máquina e a qualidade do produto associada [7]. Sua abordagem pressupõe que a qualidade do produto em tempo real pode ser obtido. Portanto, sua abordagem não pode ser aplicada a processos de fabricação sem monitoramento da qualidade do produto em tempo real. Manutenção preditiva, também conhecida como baseada em condições manutenção, tenta avaliar a condição do equipamento por meio de realizando condições de equipamento periódicas ou contínuas em tempo real monitoramento. O objetivo final da manutenção preditiva é



Fig. 2 Relação entre componentes de manutenção e parâmetros de processo

**Regression Analysis: C4(Bottom) versus T302, S302, ...**

The regression equation is  

$$C4(\text{Bottom}) = 2843 - 4.78 \text{ T302} - 32.6 \text{ S302} + 12.0 \text{ S303} + 0.0621 \text{ P303} - 1.45 \text{ S300} - 12.2 \text{ H301} + 11.5 \text{ T300}$$

Predictor	Coef	SE Coef	T	P
Constant	2842.5	193.3	14.71	0.005
T302	-4.7783	0.3080	-15.52	0.004
S302	-32.631	1.948	-16.75	0.004
S303	12.012	1.625	7.39	0.018
P303	0.062090	0.009270	6.70	0.022
S300	-1.4471	0.1720	-8.41	0.014
H301	-12.2391	0.7994	-15.31	0.004
T300	11.529	1.137	10.14	0.010

S = 0.0634356 R-Sq = 99.8% R-Sq(adj) = 99.1%

**Analysis of Variance**

Source	DF	SS	MS	F	P
Regression	7	4.23345	0.60478	150.29	0.007
Residual Error	2	0.00805	0.00402		
Total	9	4.24150			

Source	DF	Seq SS
T302	1	0.92094
S302	1	0.03940
S303	1	1.32352
P303	1	0.85988
S300	1	0.14630
H301	1	0.52976
T300	1	0.41363

**Unusual Observations**

Obs	T302	C4(Bottom)	Fit	SE Fit	Residual	St Resid
1	6.28	0.3000	0.2980	0.0633	0.0020	0.52 X

X denotes an observation whose X value gives it large leverage.

Figura 3 Resultado da análise de regressão com 13 parâmetros

realizar a manutenção em um momento programado, quando a atividade de manutenção for mais econômica e antes que o equipamento perca desempenho dentro de um limite. A manutenção baseada na condição difere da manutenção preventiva por basear a necessidade de manutenção no monitoramento da condição real da máquina, em vez de em algum cronograma predefinido [8–12].

As paradas de operação e os custos de manutenção são significativamente reduzidos com a adoção de uma estratégia de manutenção adequada [13].

Como a abordagem de manutenção corretiva é geralmente adotada no mundo real, ela é acompanhada por operações repentinas


paradas e custos adicionais devido a outras partes serem afetadas por paradas repentinas. Praticamente é impossível evitar o mau funcionamento das máquinas. Além disso, esta abordagem requer monitoramento contínuo ou de longo prazo e não pode abranger todas as máquinas ou componentes que requerem manutenção.

O método de monitoramento de status, por meio de inspeção visual, é considerado padrão e adotado pela maioria das empresas. No entanto, na prática, há muitos casos em que sensores ou raios X não podem ser usados para detectar o grau de degenerescência de uma máquina.

A manutenção preditiva está atraindo mais interesse do que a manutenção de rotina, que é realizada quando ocorre uma falha na máquina. As técnicas de manutenção preditiva ajudam a determinar a condição dos equipamentos ou sistemas em serviço, a fim de prever quando a manutenção deve ser realizada. A manutenção preditiva permite o agendamento conveniente de ações corretivas e evita paradas inesperadas do equipamento. A chave é a informação certa no momento certo. Ao saber quais equipamentos ou componentes precisam de manutenção, os trabalhos de manutenção podem ser melhor planejados, e o que seriam paradas não planejadas são transformadas em paradas mais curtas e menos planejadas, aumentando assim a disponibilidade do equipamento. Esta abordagem geralmente utiliza princípios de técnicas estatísticas de controle de processos para determinar em que ponto das futuras atividades de manutenção serão apropriadas. Para avaliar a condição do equipamento, a manutenção preditiva utiliza testes não destrutivos usando sensores, vibração, análise de nível sonoro e outros testes em tempo real. Geralmente, a manutenção preditiva inclui procedimentos que monitoram informações sobre o status da máquina e planejam o cronograma de manutenção de acordo [14–16]. Liao et al. [15] e Pan et al. [16] propuseram uma abordagem prognóstica de máquinas baseada em dados para avaliação e previsão de desempenho de máquinas.

Contudo, o monitoramento em tempo real baseado em sensores nem sempre é possível para todos os tipos de máquinas. Por exemplo, o monitoramento contínuo em tempo real das condições dos componentes ou equipamentos não está disponível para máquinas de moldagem por injeção.

Figura 4 Resultado do teste de adequação do modelo de regressão com 13 parâmetros



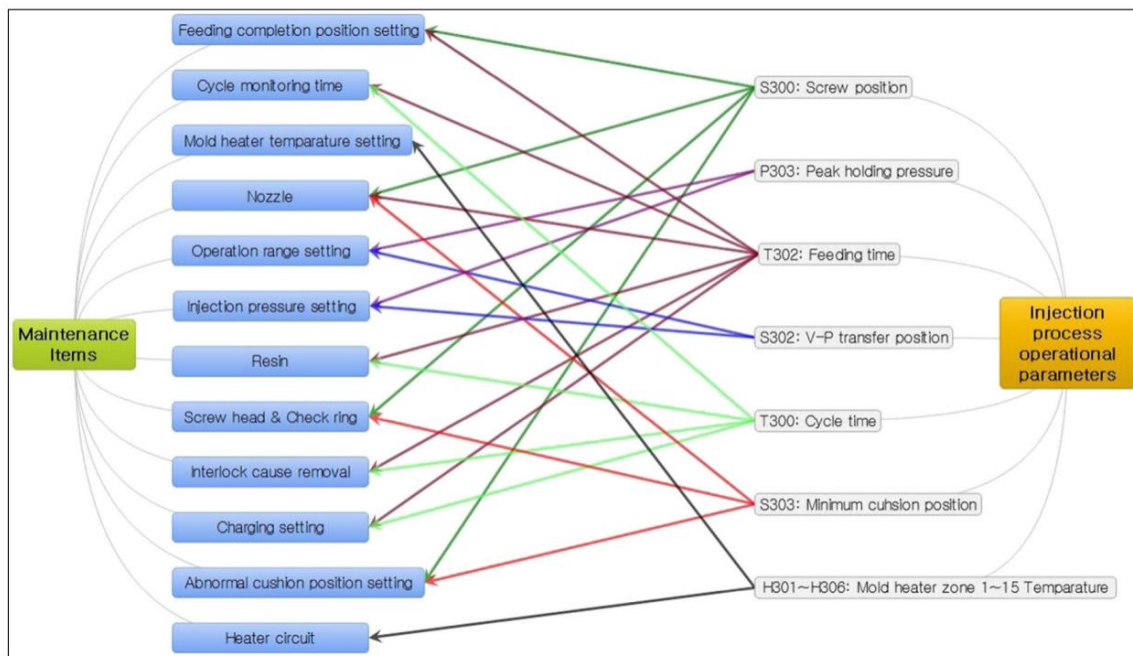


Fig. 5 Relação entre itens de manutenção e parâmetros significativos do processo

Portanto, neste artigo, propusemos uma abordagem de manutenção preditiva baseada em parâmetros de processo que é realizada em máquinas de moldagem por injeção de linhas de produção de lentes de câmeras de telefones. Primeiro, identificamos os componentes ou equipamentos da máquina de moldagem por injeção e seus parâmetros de processo relacionados e então derivou a relação de influência entre o processo parâmetros e componentes de máquinas ou equipamentos (relações muitos-para-muitos). Em segundo lugar, analisamos as séries de dados dos parâmetros do processo usando análise estatística. Nesta análise, usamos a precisão da forma esférica da lente como resposta variáveis e parâmetros de processo como variáveis independentes. A partir dos resultados da análise, identificamos os parâmetros do processo que não afetam significativamente o valor da resposta e os excluiu da lista de parâmetros do processo para o teste preditivo

abordagem de manutenção. Além disso, poderíamos assegurar que podemos prever o status dos componentes ou equipamentos por monitorar parâmetros de processo estatisticamente significativos e avaliando suas tendências ou padrões. Terceiro, derivamos modelos de previsão para parâmetros de processo significativos. Usamos séries de dados monitorados em tempo real de parâmetros de processo para o modelo de previsão. Quarto, monitoramos a série de dados em tempo real dos parâmetros do processo e os avaliou. Adotamos Nelson regras que são usadas em técnicas de controle estatístico de processos para detectar padrões ou tendências anormais. Quinto, quando padrões anormais ou tendências de parâmetros são detectados, os componentes ou equipamentos relacionados do parâmetro são encontrados consultando-se o banco de dados da árvore de falhas e os trabalhadores de manutenção são notificados. Finalmente, um sistema protótipo foi desenvolvido para mostrar viabilidade

Fig. 6 Parte dos valores de p para cada regra e suas combinações. um conjunto de valores de p para cada regra com exemplo K. b Conjunto de geral valores p para combinação de regras

Rule	K	P-value
Rule 1	4	0.0016129
	5	0.0002330
	6	0.0000034
Rule 2	9	0.0039063
	10	0.0019531
	11	0.0009766
Rule 3	5	0.0625000
	6	0.0312500
	7	0.0156250
	8	0.0078125
Rule 8	6	0.0048855
	7	0.0017722
	8	0.0006328
	9	0.0002232
	10	0.0000779

(a) Set of p-values for each rule with example K

K				Overall P-value
Rule 1	Rule 2	Rule 3	Rule 8	
4	7	5	6	0.0831382
4	7	5	7	0.0802697
4	7	5	8	0.0792199
4	7	5	9	0.0788425
4	7	5	10	0.0787087
4	7	6	6	0.0525761
4	7	6	7	0.0496120
4	7	6	8	0.0485273
4	7	6	9	0.0481373
4	7	6	10	0.0479990
4	7	7	6	0.0372951
4	7	7	7	0.0342832
4	7	7	8	0.0331809
4	7	7	9	0.0327847

(b) Set of overall p-values for rule combination





Fig. 7 Aviso de manutenção preditiva

em ambiente LabView® e um experimento foi realizado para validar nossa abordagem.

O restante do artigo está organizado da seguinte forma. Na Seção 2, é descrita uma abordagem de manutenção preditiva. Após uma introdução à nossa abordagem, a Seção 3 descreve o sistema protótipo implementado e discute os resultados da pesquisa. Finalmente, a Seção 4 conclui o artigo discutindo limitações e sugestões para a abordagem proposta.

## 2 Abordagem de manutenção preditiva

Neste artigo, propomos uma abordagem de manutenção preditiva para máquinas injetoras de uma linha de produção de lentes para câmeras de telefones celulares. O procedimento de manutenção preditiva decide o ponto de manutenção de componentes ou equipamentos usando análise de série de dados em tempo real de parâmetros de processo. A Figura 1 mostra o procedimento esquemático da nossa abordagem. A princípio, por meio de um levantamento bibliográfico, identificamos os componentes ou equipamentos de máquinas injetoras que necessitam de um alto grau de atenção para manutenção, e seus respectivos parâmetros de processo de moldagem por injeção, que são afetados pelos componentes ou equipamentos da máquina. Em segundo lugar, utilizamos análise de regressão para identificar os parâmetros que afetam significativamente a qualidade dos produtos moldados por injeção. Usamos a precisão da forma asférica da lente como indicador de qualidade e os parâmetros do processo como variáveis independentes. Através da análise de regressão, selecionamos o conjunto de parâmetros que afeta significativamente a variável resposta, ou seja, a precisão da forma asférica da lente. Isto significa que podemos prever indiretamente se alguns componentes ou equipamentos estão com defeito ou não, através do monitoramento em tempo real de parâmetros significativos do

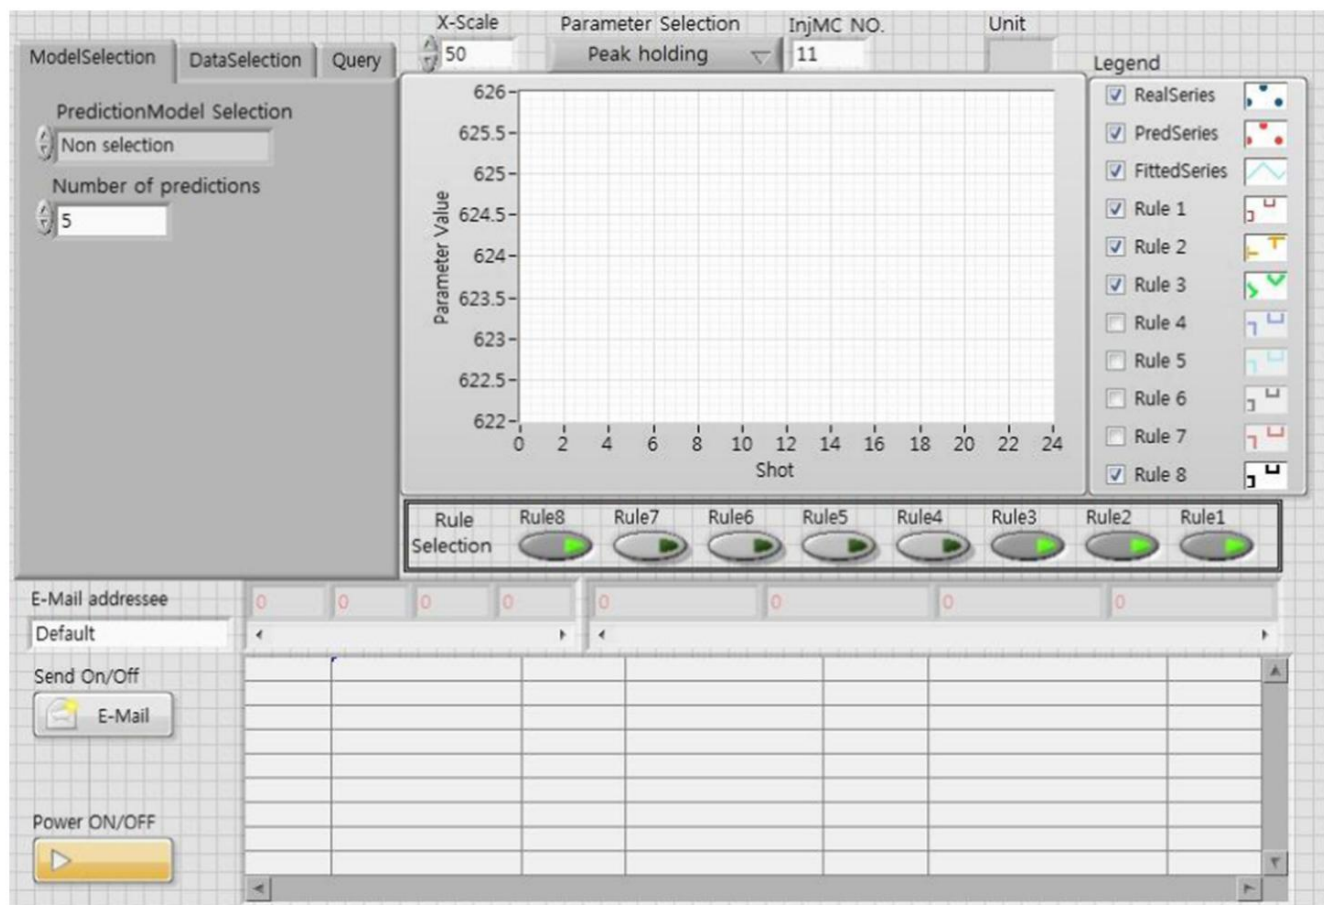


Fig. 8 Instantâneo do sistema protótipo implementado




Fig. 9 Representação esquemática da zona de aquecimento do molde 1 do barril componente

desenvolvemos modelos estatísticos de séries temporais para prever os padrões de cada parâmetro e decidir seu ponto de manutenção. momento em que padrões ou tendências anormais são detectados [17]. Finalmente, usando a série de dados de parâmetros monitorados em tempo real e valores previstos, avaliamos as tendências ou padrões em relação aos Regras de Nelson [18]. Quando padrões estatisticamente anormais são detectado, as informações de manutenção são notificadas à manutenção trabalhadores consultando o banco de dados da árvore de falhas para máquina componentes ou equipamentos. Ao consultar o banco de dados da árvore de falhas que pode relacionar os parâmetros aos equipamentos ou componentes, podemos identificar o equipamento alvo mais provável ou

Tabela 1 Série de dados da zona de aquecimento do molde 1

Tomada	Parâmetro	Data de validade
0	250	14/02/2015, 16:01:141
1	250,1	14/02/2015, 16:01:442
2	250	14/02/2015, 16:02:146
3	250	14/02/2015, 16:02:451
4	250	14/02/2015, 16:03:153
5	250	14/02/2015, 16:03:454
6	250	14/02/2015, 16:04:157
7	250	14/02/2015, 16:04:461
8	250	14/02/2015, 16:05:163
9	249,6	14/02/2015, 16:05:469
10	247,7	14/02/2015, 16:06:172
11	245,3	14/02/2015, 16:06:474
12	243,3	14/02/2015, 16:07:180
13	242	14/02/2015, 16:07:482
14	240,7	14/02/2015, 16:08:186
15	240	14/02/2015, 16:09:490
16	239,75	14/02/2015, 16:10:194
17	239,5	14/02/2015, 16:10:492
18	238,6	14/02/2015, 16:11:198
19	238,2	14/02/2015, 16:11:501
20	237,65	14/02/2015, 16:12:202
21	236	14/02/2015, 16:12:508
22	234,05	14/02/2015, 16:13:207
23	232,1	14/02/2015, 16:13:512
24	230,9	14/02/2015, 16:14:211

componente no qual realizar ações de manutenção antes ocorre uma falha grave.

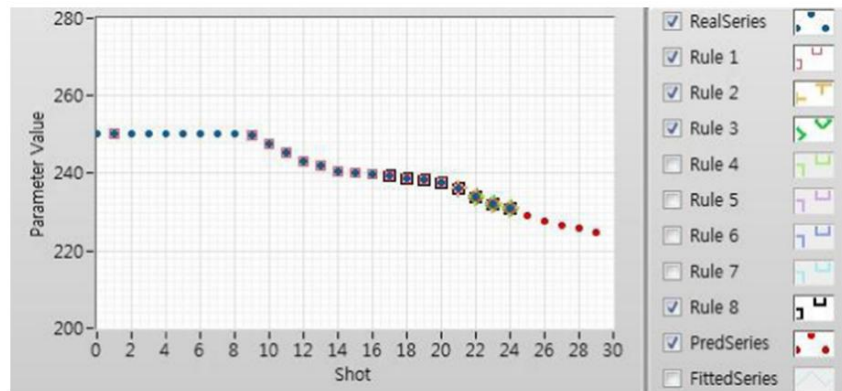
2.1 Seleção de parâmetros significativos

Através de um levantamento bibliográfico, identificamos 13 parâmetros como parâmetros candidatos do processo de moldagem por injeção que podem afetar a qualidade do produto. Também identificamos a máquina relacionada componentes ou equipamentos que afetam o status do parâmetro e então derivou a relação de influência entre componentes e parâmetros dos manuais de manutenção e pesquisa de literatura. A Figura 2 mostra a relação entre 13 parâmetros do processo e seus itens de manutenção relacionados. Então, realizamos análise de regressão para determinar os parâmetros que afetam a qualidade do produto. Usamos erro de formulário como resposta variável e 13 parâmetros como variáveis independentes. Figura 3 mostra o resultado da análise de regressão para selecionar parâmetros, e a Figura 4 mostra o resultado do teste de ajuste para nosso modelo de regressão. Os números mostram que o nosso modelo de regressão, que identificou 7 parâmetros significativos, foi adequado. Ou seja, 7 parâmetros – posição do parafuso (“S300” na figura), pico de pressão de retenção (“P303” na figura), tempo de alimentação (“T302” na figura), posição de transferência VP (“S302” na figura), tempo de ciclo (“T300” na figura), quantidade mínima de amortecimento (“S303” na figura) e zona de aquecimento do molde (“H301” e “H306” na figura) - foram significativos para nossa variável de resposta, ou seja, erro de formulário, e podemos prever a qualidade do produto monitorando esses parâmetros do processo. A Figura 5 mostra a relação reduzida entre os 7 parâmetros e seus componentes ou equipamentos relacionados. Portanto, escolhemos esses 7 parâmetros como nossos parâmetros de monitoramento para o modelo de manutenção preditiva.

2.2 Procedimento de manutenção preditiva

No modelo de manutenção preditiva, para decidir se o padrões da série de dados monitorados são anormais ou não, adotou regras de Nelson, que normalmente são utilizadas em técnicas estatísticas de controle de processos. As regras de Nelson são um método estatístico controle de processo para determinar se algumas variáveis medidas do processo estão fora de controle. As regras são aplicadas a um gráfico de controle, uma das mais famosas técnicas de controle estatístico de processos, no qual a magnitude de alguma variável do processo é plotada contra o eixo do tempo. As regras são baseadas na média valor e desvio padrão das amostras. Aplicando estes regras indica quando uma situação potencial fora de controle ocorreu surgiu. No entanto, sempre haverá alguns alertas falsos e quanto mais regras forem aplicadas, mais alertas falsos ocorrerão. Para alguns processos, pode ser benéfico omitir uma ou mais regras. Da mesma forma, pode haver alguns alertas ausentes onde alguma situação específica fora de controle não é detectada. Empiricamente, a detecção a precisão é conhecida por ser boa [18–20].

Fig. 10 Zona de aquecimento do molde 1 no experimento de moldagem por injeção



Para usar em nosso procedimento de decisão para anormalidade de padrão, selecionamos quatro regras – regras 1, 2, 3 e 8 – das oito. As regras de Nelson foram definidas porque essas quatro regras foram altamente recomendadas para uso na detecção de desgaste ou quebra de equipamentos ou componentes de máquinas [19]. Para aplicar essas quatro regras em nosso modelo de previsão, devemos escolher os valores do parâmetro K (usados como limites K sigma ou comprimento de execução K), que é usado como limite nos critérios da regra.


Para escolher os valores dos parâmetros K para cada regra do conjunto de regras, devemos selecionar um valor de erro tipo I. Na aplicação de controle estatístico de processos, cada organização fornece uma política ou orientação que pode definir uma taxa permitida de alarmes falsos ou um valor de erro tipo I em termos estatísticos. A Figura 6 mostra o conjunto de valores p para valores K em cada regra e suas combinações de quatro regras. Portanto, para um determinado valor de erro tipo I da política da empresa, podemos selecionar uma combinação de regras para usar na detecção de padrões anormais de séries de dados monitorados ou previstos em nossos modelos preditivos. Na verdade, uma vez que as séries de dados previstas são inerentemente suavizadas, outras regras além da regra 1 não têm sentido para as séries de dados previstas e, portanto, aplicamos apenas a regra 1 para detectar aqueles que estão fora dos limites K sigma para a série de dados prevista e quatro regras para a série de dados prevista. detecção de padrões anormais nas séries de dados reais monitoradas. Quando um padrão anormal é detectado nas séries de dados de qualquer parâmetro do processo, podemos identificar os itens de manutenção consultando o relacionamento mostrado na Fig. 5. A partir das informações de relacionamento e do banco de dados da árvore de falhas, a manutenção alvo

os itens são priorizados e os avisos de manutenção são enviados automaticamente aos trabalhadores da manutenção, conforme mostrado na Figura 7.

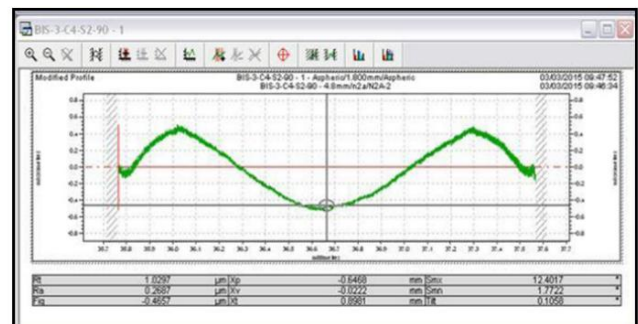
### 3 Sistema protótipo de modelo de manutenção preditiva

Neste artigo, um protótipo de sistema é desenvolvido para demonstrar a viabilidade da abordagem proposta e validá-la. O sistema protótipo é implementado usando um ambiente LabView® e SQL Server. A Figura 8 mostra o instantâneo do sistema protótipo. No canto superior esquerdo está o menu de seleção do modelo preditivo com o qual os usuários podem selecionar o modelo de previsão estatística. Os usuários podem comparar os modelos de previsão com critérios de erro quadrático médio (MSE) e selecionar um modelo adequado para usar no sistema.

Atualmente, alguns modelos, como vários modelos de regressão e de suavização exponencial, foram implementados. Na parte superior central, os usuários podem selecionar a máquina de injeção e o parâmetro do processo ao qual o modelo de previsão será aplicado e a manutenção será realizada. No lado direito, existe um menu de opções de legenda onde o usuário pode selecionar itens que serão mostrados no painel de exibição na área central. No meio da janela, existem botões de conjunto de regras com os quais os usuários podem selecionar o conjunto de regras a ser aplicado no modelo preditivo. Na área inferior da caixa de listagem, informações de status de anormalidade, como número de injeção, tempo, parâmetro, informações de manutenção, etc., são descritas quando são detectadas.




(a) lente bem formada



(b) lente deformada

Fig. 11 Resultado da medição FTS da área asférica das lentes. a lente bem formada. b Lente deformada

Fig. 12 Fotos de um aceitável lente e lente deformada. uma lente bem formada. b Lente deformada



Para demonstrar a viabilidade da nossa abordagem e validá-la, realizamos um experimento usando uma máquina de moldagem por injeção de lentes de câmera de telefone. O ciclo de moldagem por injeção começa quando o molde fecha, seguido da injeção da resina na cavidade do molde através de um bico. Para que a resina flua no bico, a matéria-prima deve ser aquecida e derretida. Uma vez a cavidade do molde é preenchida com a resina derretida, uma pressão de retenção é mantida para compensar o encolhimento do material. No próximo passo, o parafuso gira, alimentando o próximo tiro para a frente parafuso. Isso faz com que o parafuso se retraia conforme o próximo tiro é preparado. Quando o produto estiver suficientemente frio, o molde abre e o produto é ejetado. Sem operação adequada Das áreas da zona de aquecimento do molde, a matéria-prima não pode fluir suavemente para dentro da cavidade do molde e formar-se como produto alvo [21]. No experimento de teste, selecionamos a zona de aquecimento do molde temperatura (H301 na Fig. 5) como o alvo de moldagem por injeção parâmetro de processo. A Figura 9 mostra a representação esquemática das zonas de aquecimento de um bico de máquina injetora. O A área sombreada é a zona 1 do aquecedor de molde. Itens de manutenção, como “configuração de temperatura do aquecedor do molde” e “circuito do aquecedor” afetam

o parâmetro de temperatura da zona do aquecedor, conforme mostrado na Fig. 5. selecionou suavização exponencial como modelo de previsão para temperatura da zona do aquecedor.

A máquina de moldagem por injeção para este experimento é a Modelo Sumitomo de 30 toneladas (SE30DUZ) que é usado para produzir lentes de câmeras de telefones. Para as lentes, a máquina utilizou Resina EP-5000 para moldagem por injeção. Realizamos teste moldagem por injeção com um circuito de aquecimento intencionalmente quebrado durante a moldagem por injeção. Coletamos a zona de aquecimento do molde dados de temperatura usando nosso aplicativo desenvolvido de interface de controlador de máquina de moldagem por injeção. A série de dados do O parâmetro da zona 1 do aquecedor de molde é monitorado com nosso controlador aplicativo. A série de dados para a zona de aquecimento de molde 1 coletada em o experimento é mostrado na Tabela 1. A primeira coluna mostra o número do disparo de injeção, a segunda coluna mostra a zona 1 temperatura, e a terceira coluna mostra o ponto de tempo de o experimento de moldagem por injeção.

A série de dados monitorados representada na Tabela 1 é coletada e inserida no banco de dados implementado e simultaneamente plotada no painel central do display, conforme mostrado na

Fig. 13 Instantâneo do banco de dados design para manutenção proativa

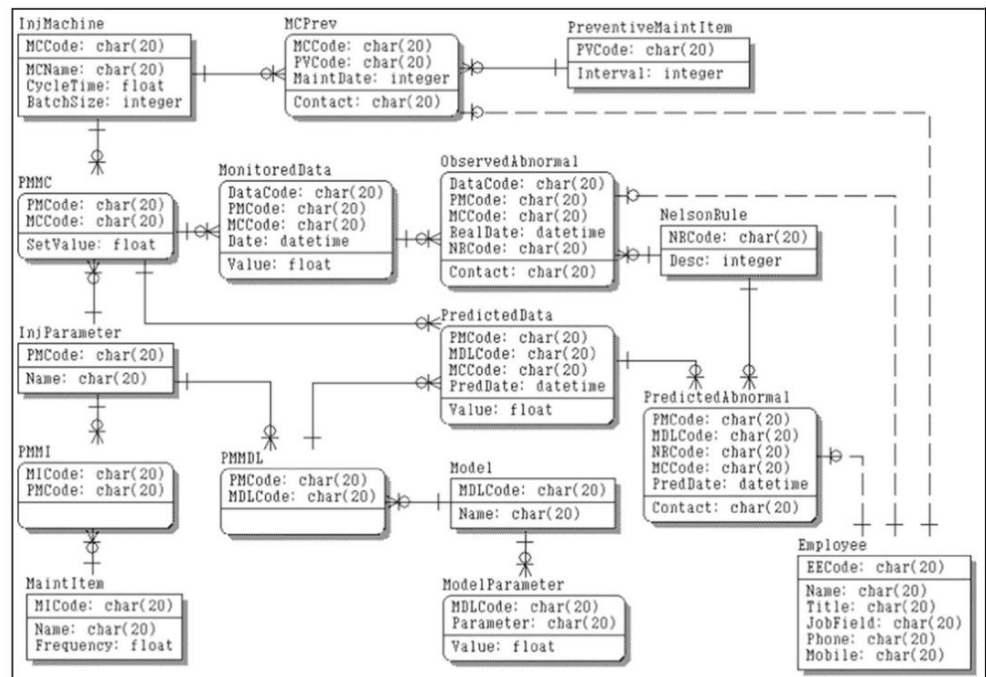




Figura 10. Sempre que novas informações de disparo são inseridas, os padrões, que são formados a partir de séries de dados recentes (com base no número de valores K), são avaliados em relação ao conjunto de regras selecionado e os resultados de anormalidade são exibidos no display central painel se houver alguma violação de regra pela série de dados.

Em nosso exemplo, quando o usuário selecionou “regra 1”, “regra 2”, “regra 3”, “regra 8”, “RealSeries” e “PredSeries” usando a legenda menu de opções, os resultados da avaliação da regra e as séries de dados previstos são mostrados no painel de exibição central. Os círculos azuis sem qualquer outra forma (fotos 0 e 2 a 8) indicam que eram fotos normais de moldagem por injeção, e os círculos vermelhos representados nas fotos 25 a 29 mostram a série de dados ajustada. Os pontos nos quadrados vermelhos (tiros 1 e 9 a 24), amarelos ouros (tiros 21 a 24), diamantes verdes (tiros 22 a 24) e os quadrados pretos (planos 17 a 24) indicam que estão violando as regras 1, 2, 3 e 8, respectivamente. Esse significa que os pontos designados anteriormente estão violando a aleatoriedade presumida. Portanto, os itens de manutenção relacionados ou componentes, o circuito do aquecedor do molde ou o ajuste de temperatura do aquecedor do molde da zona 1 devem ser notificados para examinar se funciona corretamente ou não, conforme mostrado na Fig. 7. Na Fig. 7, a frequência do circuito do aquecedor é 2 enquanto a frequência do molde a configuração da temperatura do aquecedor é zero. Isto significa que o técnico de manutenção deve verificar primeiro o circuito do aquecedor e depois o status de configuração da temperatura do aquecedor do molde.

A Figura 11 mostra os resultados da amostra para o Form Talysurf (FTS), que é usado para verificar a rugosidade da superfície e a retilidade da forma da área esférica de uma lente. A figura mostra que a área central de um corpo bem formado lente está em forma esférica, mas a área central de uma lente mal formada a lente não está na forma esférica. A Figura 12 mostra a amostra fotos de uma lente aceitável e bem moldada, que foi moldada sob boas condições de temperatura da zona de aquecimento, e uma lente deformada, que foi moldada sob condições de aquecimento anormalmente baixas condições de temperatura da zona causadas por um circuito do aquecedor quebrado.

Para gerenciar informações de manutenção, como manutenção história, relações entre parâmetros de processo e seus componentes ou equipamentos relacionados, informações da árvore de falhas, etc., desenvolvemos uma base de dados de suporte à manutenção. A Figura 13 mostra a parte do esquema do banco de dados projetada para o nosso sistema de suporte de manutenção. Inclui o necessário entidades para um sistema de manutenção preditiva.

## 4. Conclusão

Este artigo propôs uma abordagem de manutenção preditiva para um processo de moldagem por injeção. No papel, porque contínuo o monitoramento da condição do equipamento em tempo real não está disponível para máquinas de moldagem por injeção, propomos uma abordagem de manutenção preditiva que utiliza parâmetros do processo de moldagem por injeção para avaliar a condição do equipamento. Primeiro, para fornecer suporte abrangente, o documento identificou todos os possíveis

componentes ou equipamentos de manutenção com base em uma literatura enquête. Em segundo lugar, os parâmetros do processo de moldagem por injeção que são afetados pelo mau funcionamento de componentes ou equipamentos foram identificados. Para identificar parâmetros de processo que afetam significativamente a qualidade da lente, realizamos regressão análise. Terceiro, identificamos relações de influência entre parâmetros de processo e componentes de máquinas ou equipamentos através de um levantamento bibliográfico. Quarto, desenvolvemos estatísticas modelos preditivos para os parâmetros do processo que serão usados para detectar anormalidades nos padrões de séries de dados. Finalmente, desenvolvemos um sistema protótipo para uma abordagem de manutenção preditiva usando um exemplo experimental para demonstrar como a manutenção preditiva pode ser gerenciada de forma eficaz e validar nossa abordagem. A abordagem proposta também pode ser aplicado a máquinas de fabricação similares.

Outras questões de pesquisa incluem a aplicação de mais previsões modelos como rede neural ou SVM. Além disso, para itens de manutenção que não são cobertos pela manutenção preditiva, uma abordagem de manutenção preventiva pode ser adicionalmente aplicado com base no período de verificação dos componentes ou equipamentos de manutenção.

Agradecimentos Este trabalho foi apoiado pelo Programa de Desenvolvimento de Tecnologia Estratégica Industrial (10040952, Desenvolvimento de sistema de moldagem por injeção baseado em BIS com capacidade de resposta rápida e inteligência autônoma) financiado pelo Ministério da Economia do Conhecimento de Coreia, e também pela Universidade Nacional de Changwon em 2013y2014.

## Referências

- Blanchard BS (1995) Manutenção: uma chave para uma gestão eficaz da capacidade de serviço e da manutenção. Wiley, Nova York, pp 3–10
- Salonen A, Deleryd M (2011) Custo da má manutenção: um conceito para melhoria do desempenho da manutenção. J Qual Manutenção Eng 17(1):63–73. doi:10.1108/13552511111116259
- Dhillon BS, Liu Y (2006) Erro humano na manutenção: uma revisão. J. Qual Maint Eng 12(1):21–36. doi:10.1108/13552510610654510
- Organização Internacional de Normalização (2011) ISO 17359: 2011—Monitoramento de condição e diagnóstico de máquinas—diretrizes gerais
- Blischke WR, Murthy DP (2003) Estudos de caso em confiabilidade e manutenção. Wiley, Nova York, pp 353–375
- Campbell JD, Andrew KSJ (2001) Excelência em manutenção: otimizando decisões sobre o ciclo de vida do equipamento (Dekker Mechanical Engenharia). Marcel Dekker, Inc., Nova York, pp 323–366
- Lee S, Ni J (2013) Tomada de decisão conjunta para manutenção e programação de produção de sistemas de produção. Int J Adv Manuf Technol 66(5–8):1135–1146. doi:10.1007/s00170-012-4395-6
- Greenough RM, Grubic T (2011) Modelagem de manutenção baseada em condições para fornecer um serviço a usuários de máquinas-ferramenta. Int J Adv Manuf Technol 52(9–12):1117–1132. doi:10.1007/s00170-010-2760-x
- Naderkhani ZGF, Makis V (2015) Política de manutenção baseada em condições ideal para um sistema parcialmente observável com duas amostragens intervalos. Int J Adv Manuf Technol 78(5–8):795–805. doi:10.1007/s00170-014-6651-4
- Palem G (2013) Manutenção baseada em condições usando conjuntos de sensores e telemática. Int J Mob Netw Comm & Telem 3(3):19–28. faça: 10.5121/ijmnet.2013.3303

11. Peng Y, Dong M, Zuo MJ (2010) Status atual do programa da máquina nostics em manutenção baseada em condições: uma revisão. *Int J Adv Manuf Technol* 50(1–4):297–313. doi:[10.1007/s00170-009-2482-0](https://doi.org/10.1007/s00170-009-2482-0)
12. Yam RCM, Tse PW, Li L, Tu P (2001) Sistema inteligente de apoio à decisão preditiva para manutenção baseada em condições. *Int J Adv Manuf Technol* 17(5):383–391. doi:[10.1007/s001700170173](https://doi.org/10.1007/s001700170173)
13. Pinjala SK, Pintelon L, Vereecke A (2006) Uma investigação empírica sobre a relação entre estratégias de negócios e manutenção. *Int J Prod Econ* 104(1):214–229. doi:[10.1016/j.ijpe.2004.12.024](https://doi.org/10.1016/j.ijpe.2004.12.024)
14. Niebel BW (1994) *Gestão de manutenção de engenharia*. Marcel Dekker, Inc., Nova York, pp 146–188
15. Liao W, Wang Y, Pan E (2012) Modelo de manutenção preditiva baseado em máquina única considerando prognósticos de máquinas inteligentes. *Int J Adv Manuf Technol* 63(1–4):51–63. doi:[10.1007/s00170-011-3884-3](https://doi.org/10.1007/s00170-011-3884-3)
16. Pan E, Liao W, Xi L (2012) Um modelo conjunto de programação de produção e manutenção preditiva para minimizar atrasos no trabalho. *Int J Adv Manuf Technol* 60(9–12):1049–1061. doi:[10.1007/s00170-011-3652-4](https://doi.org/10.1007/s00170-011-3652-4)
17. Box G, Jenkins GM, Reinsel GC (2008) *Análise de séries temporais: previsão e controle*, 4ª ed. Wiley, Nova York, pp 93–136
18. Nelson LS (1984) *Gráfico de controle de Shewhart – testes para causas especiais*. J Qual Technol 16(4):238–239
19. Bae DS, Ryu MC, Kwon YI, You WY, Kim SB, Hong SH, Choi IS (2010) *Controle estatístico de qualidade*. Youngchi, Seul, pp 271–295
20. Nelson (2015) *Regras de Nelson*. [https://en.wikipedia.org/wiki/Nelson\\_regras](https://en.wikipedia.org/wiki/Nelson_regras). Acessado em agosto de 2015
21. Osswald T, Turng LS, Gramann P (2008) *Manual de moldagem por injeção*, 2ª ed. Hanser, Munique, pp 13–18